

STT 없이 음향 특징만으로 개인정보(PII) 형식 숫자열을 탐지하는 경량 CNN의 타당성 연구

김현찬 박승진 강진구
승실대학교 미디어학과

2026년 8월

Abstract

음성 데이터에서 개인정보(Personally Identifiable Information, PII)를 탐지하는 표준 방식은 자동음성인식(Automatic Speech Recognition, ASR)으로 발화를 텍스트로 전사(Speech-to-Text, 이하 STT)한 뒤 자연어처리(Natural Language Processing, NLP)로 민감 정보를 찾는 캐스케이드 구조이다. 그러나 이 방식은 (1) 모든 발화를 전사해야 하는 비용과 지연, (2) 전사 텍스트 자체가 민감정보 유출 표면이 되는 문제, (3) 전사 오류가 후단으로 전파되는 문제를 안고 있다. 본 연구는 전사 과정을 건너뛰고, 음성 신호를 멜 스펙트로그램으로 변환한 뒤 경량 합성곱신경망(Convolutional Neural Network, CNN)이 “PII 형식 숫자열”의 포함 여부를 직접 판별하는 접근의 타당성(feasibility)을 통계 실험으로 검증한다. 직접 설계한 60,706 파라미터 CNN은 $F1 = 0.955 \pm 0.010$, $ROC-AUC = 0.997 \pm 0.001$ 로 음향 통계 기반 로지스틱 회귀 기준선(0.761 / 0.878)을 크게 능가하였다. 성능이 인공 단서에서 온 것이 아님은 두 겹의 통계 실험으로 확인하였다. 길이 분포를 맞춘 평가셋에서 길이 기반 기준선은 우연 수준으로 붕괴하지만 CNN의 F1은 그대로였고(0.956 대 0.955), negative를 비PII 숫자열로만 좁힌 가장 어려운 조건에서도 CNN은 정밀도 0.998, ROC-AUC 0.999로 다섯 평가셋 가운데 가장 높았다(이상 전화번호 단일 유형인 v1 조건, hard-negative 오답률 0.006). 일반화는 두 축 모두에서 성립하였다. 학습에 없던 화자에 대한 leave-one-speaker-out(LOSO) 평가에서 순위 성능은 v1 아홉 폴드 전부 ROC-AUC 0.97 이상(0.992 ± 0.008)이었고, 화자를 14명으로 늘리자 고정 임계값 기준 F1이 0.616 ± 0.280 에서 0.861 ± 0.102 (중앙값 0.904)로 안정화되었다. 학습에서 완전히 제외한 세 PII 유형(주민/카드/계좌)도 재현율 0.88–0.98로 탐지되었다. Whisper 기반 STT+NLP 표준 경로와 동일 인스턴스에서 비교하면 두 접근의 실패 지점이 갈린다. 16자리 카드번호에서 STT+NLP 재현율이 0.852인 반면 CNN은 81개 전부를 검출하였고(1.000), 전체 재현율 0.989 대 0.921, 추론 지연은 약 1,000배 빨랐다. 반대로 정밀도는 STT+NLP가 0.951 대 0.708로 앞선다. 이 상보성을 근거로 “CNN 프리필터 → STT+NLP 확정”의 2단계 파이프라인을 제안한다. 본 결과는 음성합성(Text-to-Speech, TTS)으로 만든 합성 데이터에 한정된다. 또한 PII 유형을 넷으로 늘리면 형식이 충돌하는 긴 숫자열 때문에 hard-negative 오답률이 0.42–0.54로 오르므로, 운용 정밀도 개선과 실통화 검증을 남은 과제로 명시한다.

1 서론

콜센터 상담, 회의 녹취, 음성 메모 등 음성 데이터에는 전화번호, 주민등록번호, 계좌번호, 카드번호와 같은 개인정보(Personally Identifiable Information, PII)가 빈번하게 포함된다. 개인정보보호 규제 준수와 데이터 최소화 원칙을 위해 이러한 민감 정보를 자동으로 탐지하고 비식별화(redaction)하려는 수요가 크다. 현재 표준적인 접근은 음성을 자동음성인식(Automatic Speech Recognition, ASR)으로 전사한 뒤 전사 텍스트에 자연어처리(Natural Language Processing, NLP) 기법인 개체명인식(Named Entity Recognition, NER)이나 정규식 패턴 매칭을 적용해 민감 구간을 찾고, 그 구간에 대응하는 오디오를 마스킹하는 캐스케이드 파이프라인이다 [1]. 주요 상용 서비스와 실시간 상담

시스템이 모두 이 구조를 채택하고 있다 [2,3]. 이하에서는 이 전사 단계를 관례에 따라 STT(Speech-to-Text)로도 부르며, ASR과 같은 뜻으로 사용한다.

이 구조는 세 지점에서 비용을 치른다. 우선 PII 포함 여부와 무관하게 모든 발화를 전사해야 하므로, 대량 녹취를 다룰수록 STT 호출 비용이 선형으로 증가한다. 본 연구에서 측정한 Whisper-large-v3 [4]의 전사 지연은 클립당 약 360 ms인 반면, 뒤에서 제안할 경량 합성곱신경망(Convolutional Neural Network, CNN)의 추론 지연은 5초 원도당 0.344 ms로 약 1,000배의 차이가 난다(측정 조건은 4장). 여기에 더해 탐지 과정 자체가 민감 텍스트를 중간 산출물로 남긴다. 전사 텍스트는 PII를 평균으로 담게 되어 로그, 캐시, 저장소 전반에 새로운 유출 표면을 만들며, 공개된 상담 전사 데이터셋들이 배포 전에 별도의 비식별화 공정을 거쳐야 하는 이유도 여기에 있다 [5]. 탐지 단계에서 텍스트를 만들지 않으면, 적어도 선별에서 걸러지는 대부분의 발화에 대해서는 이 표면이 발생하지 않는다. 마지막으로, 전사 오류는 그대로 후단으로 전파된다. 본 연구의 비교 실험에서도 일반 발화의 단어 오류율(Word Error Rate, WER) 중앙값이 0인 합성음 조건에서조차 숫자열 구간에서는 자릿수의 병합과 분질이 발생하여, 16자리 카드번호에 대한 STT+NLP 재현율이 0.852에 그쳤다. 전사 품질 전반이 좋더라도 오류가 하필 숫자열 구간에 집중된다는 뜻이다.

본 연구의 출발점은 다음 관찰이다. 전화번호나 계좌번호처럼 PII로 취급되는 숫자열은 낭독될 때 개별 숫자가 일정한 리듬으로 연속되고 자릿수 그룹 사이에 짧은 휴지가 놓이는, 비교적 규칙적인 시간-주파수 패턴을 만든다(그림 2). 본 연구는 이 패턴 가설을 검증한다. 성립한다면 “어떤 숫자가 발화되었는가”라는 어휘 정보를 복원하지 않고도 “숫자열이 PII의 형식을 띠는가”라는 상위 패턴을 음향 표현만으로 판별할 수 있고, 전사 없이 동작하는 저비용 선별기를 캐스케이드 앞단에 배치하여 위의 세 비용을 동시에 완화할 수 있다.

이 가능성을 검증하기 위해 본 연구는 다음 다섯 가지 연구 질문(Research Question, RQ)에 답한다. 첫째, STT 없이 음향 특징만으로 PII 형식 숫자열을 탐지하는 것이 실제로 가능한가, 즉 타당성이 성립하는가(RQ1). 둘째, 모델이 진짜 “PII 형식”을 학습하는가, 아니면 발화 길이나 단순한 “숫자 존재” 여부, 화자 지문 같은 인공 단서(artifact), 즉 과제의 본질과 무관한 지름길(shortcut) 단서 [6]로 맞히는가(RQ2). 셋째, 학습에 없던 화자와 학습에서 제외한 PII 유형으로 일반화되는가(RQ3). 넷째, 표준 경로인 STT+NLP와 비교했을 때 어떤 운용 위치가 합리적인가(RQ4). 다섯째, 이 과제에 적합한 모델 규모는 어디인가, 즉 대규모 사전학습 백본이 소형 전용 모델보다 유리한가(RQ5).

이를 위해 지름길 단서를 차단하도록 설계한 한국어 합성 음성 데이터셋을 구축하였다. 핵심 설계 결정은 두 가지다. 하나는 클래스를 가리지 않고 문장 안의 모든 숫자를 한국어 자릿수 발음으로 강제 변환하여, 두 클래스의 차이가 “읽는 방식”이 아니라 “숫자열 형식”만 남게 한 것이다. 다른 하나는 PII가 아닌 숫자열(날짜, 가격, 주문번호 등)을 담은 어려운 음성 표본(hard-negative)을 negative의 상당 부분으로 투입하여, “숫자가 들린다”는 단서만으로는 과제가 풀리지 않게 한 것이다.

본 연구의 기여는 다음 다섯 가지이다. (i) STT-free 음향 PII 형식 탐지 과제를 정식화하고, 지름길 단서를 차단한 통제 데이터셋과 템플릿 누수 없는 평가 프로토콜을 설계하였다. (ii) 길이 불변과 “숫자 존재”-“형식” 분리라는 두 겹의 통제 실험, 그리고 낭독 방식 동일과 출처 지문 동일이라는 두 겹의 설계 통제로 높은 성능이 지름길 단서로 설명되지 않음을 보였다. (iii) 화자(LOSO)와 PII 유형(held-out) 두 축의 일반화를 정량적으로 검증하였다. (iv) STT+NLP 표준 경로와 동일 조건에서 직접 비교하여 두 접근의 실패 지점이 상보적임을 규명하고 2단계 파이프라인을 제안하였다. (v) 동일한 학습 예산에서 60,706 파라미터 경량 CNN이 27.8M 파라미터의 ImageNet 사전학습 백본을 일반화·PR-AUC·지연 세 축 모두에서 능가함을 보였다.

이후 논문의 구성은 다음과 같다. 2장에서 관련 연구를 정리하고, 3장에서 과제 정식화와 데이터 생성 과정을, 4장에서 특징 추출, 모델, 분할과 학습, 평가 프로토콜을 기술한다. 5장에서 실험 결과를 제시하고 6장에서 논의한 뒤, 합성 음성이라는 통제 조건에서 얻은 결과의 범위를 7장에서 밝히고 8장에서 결론을 정리한다.

2 관련 연구

2.1 ASR → NLP 캐스케이드 기반 음성 비식별화

음성에서 PII를 제거하는 문제는 Cohn 등 [1]이 오디오 비식별화라는 개체명 인식 과제로 정식화하였다. 이들은 ASR로 전사한 뒤 전사 텍스트에서 개체명을 인식하고 다시 오디오 구간으로 정렬하는 세 단계 파이프라인과 그에 맞는 평가 지표를 제안했으며, 이 구조가 이후 상용 시스템의 사실상 표준이 되었다 [2]. TruSera [3]는 이를 실시간 상담으로 확장하여 ASR과 자연어이해 모듈, 오디오 레닥터를 파이프라인으로 연결해 상담원이 카드번호를 듣지 않도록 하면서 대화의 자연스러움을 유지한다. 대규모 상담 전사 데이터셋을 공개한 연구 [5]에서도 배경 잡음과 교차 발화 같은 요인이 전사 품질에 영향을 준다는 점, 그리고 공개 전에 별도의 PII 비식별화 공정이 필요하다는 점이 보고된다.

이러한 시스템들이 공통적으로 안는 구조적 취약성은 텍스트 단계가 ASR 출력에 전적으로 의존한다는 데 있다. 구어 숫자는 발화 속도와 휴지에 따라 다르게 전사되고, 하나의 번호가 여러 토큰이나 여러 발화 구간으로 분절되며, 숫자 하나가 누락되어도 형식 매칭이 실패한다. 본 연구의 5장 실험은 이 취약성을 합성음이라는 최상 조건에서도 정량적으로 재현한다. 본 연구는 이 캐스케이드를 대체하려는 것이 아니라, 그 앞단에 전사 없이 동작하는 경량 선별기를 두어 호출량과 유출 표면을 함께 줄이는 것을 목표로 한다.

2.2 ASR-free / 종단간 음성언어이해

본 연구와 방법론적으로 가장 가까운 계보는 음성에서 의미를 ASR 없이 직접 추론하는 종단간(end-to-end) 음성언어이해(Spoken Language Understanding, SLU) 연구이다. Serdyuk 등 [7]은 전사 텍스트를 전혀 거치지 않고 음향 특징에서 곧바로 의도를 예측하는 구조가 가능함을 보였고, Lugosch 등 [8]은 ASR 과제로 사전학습한 음향 인코더를 SLU로 전이하여 적은 라벨로도 높은 정확도를 얻는 방법을 제시하였다. Palogiannidi 등 [9]은 ASR 수준의 라벨이나 사전학습 모델 없이도 순환 구조와 데이터 증강만으로 경쟁력 있는 결과를 얻을 수 있음을 보였으며, Tomashenko 등 [10]은 개체명 인식과 슬롯 채우기를 음성에서 직접 수행하기 위해 화자 적응, 연결주의 시간 분류(Connectionist Temporal Classification, CTC) 학습 기준의 변형, 순차적 사전학습을 제안하고 평가하였다. 최근에는 자기지도 학습된 음향 인코더에 CTC 보조 손실을 결합하여 성능을 끌어올리는 접근도 제안되었다 [11]. 이들 연구가 공유하는 동기는 본 연구와 상당 부분 겹친다. 전사 단계를 제거하면 ASR 오류가 후단으로 전파되지 않고, 시스템이 단순해지며, 텍스트라는 중간 표현이 만드는 병목이 사라진다. 여기에 더해 본 연구는 중간 텍스트가 생성되지 않는다는 사실 자체를 프라이버시 측면의 이득으로 명시적으로 다룬다.

그러나 문제 설정과 운용 목표에서는 네 가지 차이가 있다. 첫째, 라벨 공간이 다르다. 기존 SLU 연구의 목표는 의도(intent)나 슬롯(slot)처럼 어휘에 대응되는 의미 범주인 반면, 본 연구의 목표는 “PII의 형식을 갖춘 숫자열이 존재하는가”라는 비어휘적 상위 패턴이다. 어떤 숫자가 발화되었는지는 라벨과 무관하며, 오히려 같은 숫자 어휘가 두 클래스 모두에 등장한다. 둘째, 운용 목적이 다르다. 기존 연구는 최종 이해 결과의 정확도를 겨루지만, 본 연구의 모델은 뒤따르는 정밀 파이프라인의 호출량을 줄이는 프리필터이므로, 균형 잡힌 정확도보다 고재현율과 초저지연이라는 비대칭적 운용점이 중요하다. 셋째, 평가의 초점이 다르다. 본 연구는 벤치마크 점수 경쟁이 아니라, 높은 점수가 지름길 단서에서 온 것이 아님을 보이는 통제 실험에 초점을 둔다. 넷째, 모델 규모가 다르다. 기존 종단간 SLU가 수천만에서 수억 파라미터의 사전학습 음향 인코더를 사용하는 데 반해, 본 연구는 60,706 파라미터의 전용 CNN을 처음부터 학습한다. 또한 PII 형식 라벨과 통제된 hard-negative를 함께 갖춘 한국어 음성 데이터는 공개된 바 없어 기존 SLU 벤치마크를 재사용할 수 없고, 3장과 같은 자체 데이터 설계가 필요하다.

2.3 키워드 스포팅과 경량 음향 분류

멜 스펙트로그램과 소형 신경망으로 특정 어휘를 저전력에서 탐지하는 키워드 스포팅(Keyword Spotting, KWS)은 본 연구가 사용하는 구현 기법을 공유하는 영역이다. Sainath와 Parada [12]는 CNN이 완전연결 신경망보다 훨씬 적은 파라미터로 더 낮은 오거부율을 달성함을 보였고, Tang과 Lin [13]은 잔차 연결과 팽창 합성곱으로 소형 모델의 정확도를 끌어올렸으며, Berg 등 [14]은 자기 어텐션 기반 구조로 이를 확장하였다. 후속 연구들은 대부분 고립 단어 코퍼스 [15]에서 평가된다. 한편 대규모 오디오 분류에서는 AudioSet으로 사전학습한 CNN(Pretrained Audio Neural Networks, PANNs) [16]이나 스펙트로그램 트랜스포머(Audio Spectrogram Transformer, AST) [17]가 표준적인 표현 학습 방법으로 자리 잡았다. 이들은 범용 음향 사건 표현을 제공하지만 파라미터가 수천만 개에 달해 상시 동작하는 프리필터의 예산에는 맞지 않는다. 본 연구가 5장에서 ImageNet 사전학습 백본을 비교군으로 삼은 것은 “큰 사전학습 모델이 이 과제에서 유리한가”를 직접 묻기 위해서이다.

본 연구는 KWS와 적용 범위뿐 아니라 기술적 구성에서도 구분된다. 첫째, 탐지 단위가 다르다. KWS는 고정된 어휘 목록의 각 항목에 대응하는 짧은 음향 앵커를 학습한다. 최근에는 음소열이나 예시 발화를 질의로 받는 개방 어휘 KWS도 제안되었으나, 이들 역시 질의를 어휘적 단위(음소열이나 예시 음향)로 명시해야 한다는 점은 같다. 본 연구의 탐지 대상에는 그렇게 명시할 수 있는 앵커 자체가 없으며, 판별에 쓰이는 신호는 개별 숫자의 정체가 아니라 숫자 낭독 구간의 지속 길이, 자릿수 그룹 경계에 놓이는 휴지의 배치, 반복되는 리듬 같은 시퀀스 구조이다. 둘째, 입력 길이와 집계 방식이 다르다. KWS는 1초 내외의 고정 윈도우에서 프레임별 사후확률을 매끄럽게 만들어 판정하지만, 본 연구는 5초 윈도우를 2.5초 간격으로 이동시키며 윈도우 단위 확률의 최댓값으로 클립 점수를 정한다. 추론 시 윈도우 점수를 최댓값으로 모으는 이 집계는 다중 인스턴스 학습(multiple instance learning)의 추론 규칙과 같은 형태이며, 숫자열이 윈도우 경계에 걸쳐도 놓치지 않기 위해 필요하다. 셋째, 판별 난이도의 구조가 다르다. 본 연구의 positive와 hard-negative는 동일한 숫자 어휘 집합으로 이루어져 있어, 어떤 숫자 단어가 등장했는지만 판정하는 KWS식 어휘 집합 탐지로는 두 클래스를 분리할 수 없다. 두 클래스를 가르는 정보는 어휘의 목록이 아니라 그 배열, 즉 연속 자릿수의 길이와 그룹 경계에 있다. 넷째, 학습 데이터의 성격이 다르다. 고립 단어가 아니라 캐리어 문장에 삽입된 연속 발화를 사용하며, 문장 템플릿이 분할 간에 겹치지 않도록 통제한다. 요컨대 본 과제는 “무엇이 들렸는가”가 아니라 “들린 숫자들이 어떤 구조로 배열되었는가”를 묻는 문제이며, 그 때문에 KWS에서 표준인 어휘 단위 사후확률 설계 대신 윈도우 최댓값 집계와 hard-negative 통제가 요구된다.

2.4 음성 콘텐츠 프라이버시

음성 프라이버시 연구는 화자 신원 은닉에서 출발하여 최근에는 발화 내용 자체의 보호로 확장되고 있다. 화자 신원을 지우는 익명화가 “누가 말했는가”를 다루는 문제라면, 본 연구가 속한 콘텐츠 프라이버시는 “무엇을 말했는가” 가운데 민감한 부분을 골라내는 문제이며, 두 축은 보호 대상이 서로 직교하여 실제 운용에서는 함께 적용될 수 있다. Williams 등 [18]은 음성이 단어와 의미뿐 아니라 문체, 병리적 특징, 억양, 감정까지 드러낸다는 점에서 콘텐츠 프라이버시가 별도의 과제임을 지적하고, 상용 솔루션이 이용자에게 충분한 프라이버시 선택지를 제공하지 못하고 있음을 논한다. Preech [19]는 전사 파이프라인 자체를 프라이버시 보존적으로 재구성하여, 음성을 분절·치환한 뒤 외부 전사 서비스에 보내고 결과를 복원함으로써 화자 특성과 텍스트 내용을 동시에 보호한다. 본 연구는 이들과 보호 지점이 다르다. Preech가 “전사를 하되 안전하게 하는” 접근이라면, 본 연구는 “대부분의 발화에 대해 전사 자체를 하지 않는” 접근으로, 탐지 단계에서 이진 신호만 산출하여 민감 텍스트가 생성되는 사건 수를 줄인다. 두 접근은 배타적이지 않으며, 프리필터를 통과한 소수의 발화에 프라이버시 보존 전사를 적용하는 결합도 가능하다.

2.5 연구 공백과 본 연구의 위치

표 1의 네 축을 함께 놓고 보면 본 연구의 위치가 드러난다. 본 연구는 텍스트를 생성하지 않는다는 점에서 종단간 SLU 및 KWS와 같은 쪽에 서지만, 라벨이 어휘가 아닌 형식이라는 점에서 두 계보 모두와 달라진다. 또한 성능 수치 자체보다 그 수치가 지름길 단서에서 오지 않았음을 보이는 통제와, 화자·PII 유형 두 축의 일반화 검증에 지면을 배분한다는 점에서 벤치마크 경쟁형 연구와 목적이 다르다. 본 연구는 이 위치에서 표준 경로와 직접 비교하여, 제안 접근이 대체재가 아니라 보완재임을 밝힌다.

표 1: 선행 연구와 본 연구의 위치 비교. “단서 통제 검증”은 높은 성능이 과제와 무관한 지름길 단서에서 오지 않았음을 별도 실험으로 확인했는지를 뜻한다.

접근	중간 텍스트	라벨 공간	운용 목적	단서 통제 검증
캐스케이드 비식별화 [1-3]	생성함	어휘/개체명	정밀 확정	해당 없음
종단간 SLU [7-11]	생성 안 함	의도·슬롯(어휘 대응)	최종 이해	보고 안 함
키워드 스포팅 [12-14]	생성 안 함	고정 어휘	상시 대기 트리거	보고 안 함
프라이버시 보존 전사 [19]	생성함(보호)	텍스트 전체	안전한 전사	해당 없음
본 연구	생성 안 함	숫자열 형식(비어휘)	프리필터	길이·숫자존재(실험)

3 과제 정식화 및 데이터셋

3.1 과제 정의

입력은 5초 음향 원도의 로그 멜 스펙트로그램 $\mathbf{X} \in \mathbb{R}^{64 \times 157}$ 이며(멜 채널 64, hop 512 표본에서 유도되는 프레임 수 157), 모델은 원도가 PII 형식 숫자열을 포함할 확률 $f(\mathbf{X}) = \text{softmax}(g(\mathbf{X}))_1 \in [0, 1]$ 을 출력한다. 여기서 g 는 2차원 로짓을 내는 신경망이다. 클립 c 에 대해 $W(c)$ 는 그 클립을 2.5초 간격의 sliding window로 덮어 얻은 5초 원도들의 집합이며(클립이 5초보다 짧으면 저진폭 노이즈로 패딩한 원도 한 개), 클립 점수는 $s(c) = \max_{\mathbf{X} \in W(c)} f(\mathbf{X})$ 로 정의한다. 최종 판정은 임계값 τ 에 대해 $\hat{y}(c) = \mathbb{I}[s(c) \geq \tau]$ 이며, 별도로 밝히지 않는 한 $\tau = 0.5$ 를 사용한다. 프리필터 관점에서 $\Pr[s(c) \geq \tau]$ 는 뒤따르는 STT 단계로 넘어가는 클립의 비율, 즉 STT 호출률에 해당한다.

Positive는 전화번호, 주민등록번호, 계좌번호, 카드번호를 포함한 발화이고, negative는 PII가 아닌 숫자열을 포함한 hard-negative와 숫자열이 핵심 정보가 아닌 일반 발화 easy-negative로 구성한다. 본 과제는 “문맥상 실제로 민감한가”를 판단하는 것이 아니라 “PII 형식 숫자열이 음향적으로 존재하는가”를 판별하는 것으로 한정한다. 따라서 “이건 예시 번호입니다”처럼 문맥상 실제 PII가 아니더라도 형식이 들리면 positive로 라벨링하며, v1 데이터셋은 이런 문맥 변형 positive를 전체의 20%로 포함한다. 문맥 판단은 5장에서 비교하는 STT+NLP 단계의 역할이며, 본 모델은 그 앞단의 형식 선별기이다.

3.2 데이터 생성 파이프라인

PII가 포함된 실제 음성은 정의상 수집·공개가 불가능하므로, 본 연구는 통제 가능한 합성 음성 데이터셋을 직접 구축하였다. 생성은 그림 1과 같이 네 단계로 이루어진다. 이하의 사양은 v2를 기준으로 서술하고, v1과 다른 점은 각 단계 끝에 밝힌다.

(1) 문장과 값 생성. PII 유형별로 문장 템플릿을 두고(전화 5종, 주민 4종, 계좌 4종, 카드 3종), 각 발화마다 형식만 유효한 난수 값을 생성하여 삽입한다. 전화번호는 010-XXXX-XXXX(11자리), 주민등록번호는 YYMMDD-Gxxxxxx(13자리), 계좌번호는 3-3-6(11-12자리), 카드번호는 4-4-4-4(16자리) 형식이다. 값은 난수이므로 실재하는 번호가 아니다. hard-negative는 날짜, 주문번호(9-11자리),




그림 1: 데이터 생성 파이프라인. 문장 템플릿에 형식만 유효한 난수 PII 값을 삽입하고, hard-negative에는 캐리어 문장을 결합해 positive와 길이 분포를 맞춘 뒤, 모든 숫자를 한국어 자릿수 발음으로 정규화하여 TTS로 합성한다. v2에서는 VoiceDesign으로 만든 화자별 참조 음성 1개를 Base 모델이 복제하여 14명의 일관된 합성 화자를 얻는다.

송장번호(4+4자리), 가격, 우편번호(5자리), 좌석번호, 제품 일련번호(4+4+4자리), 생일, 버스번호, 수 세기의 10개 카테고리 생성기로 만들며, 우연히 전화번호 형식이 만들어지면 정규식으로 검출해 재생성한다. easy-negative는 숫자를 포함하지 않는 12종의 일반 문장이다.

v1은 전화번호 단일 유형만 다루므로 구성이 다르다. v1의 positive는 숫자열을 문장 앞·중간·끝에 배치한 일반 템플릿 10종과, “{v} 형식은 예시입니다”처럼 문맥상 실제 PII가 아니지만 형식은 들리는 문맥 변형 템플릿 4종(전체의 20%)으로 이루어진다. v1의 hard-negative 카테고리는 날짜, 주문번호, 송장번호, 호실, 창구번호, 버스번호, 가격, 수량, 우편번호, 수 세기의 10종으로 v2와 일부 다르며, 카드번호와 충돌하도록 설계한 제품 일련번호와 좌석번호는 PII 유형을 확장한 v2에서 추가되었다.

(2) 캐리어 문장 결합과 길이 정렬. hard-negative의 핵심 문장은 positive보다 짧아, 그대로 두면 클립 길이가 클래스 단서가 된다. 이를 막기 위해 hard-negative에는 85% 확률로 “안내 말씀드립니다”, “확인 부탁드립니다” 같은 숫자 없는 안내 문구를 앞이나 뒤에 결합하였다. 실제로 v2 hard-negative의 길이 중앙값은 캐리어가 붙은 경우 4.72초, 붙지 않은 경우 3.04초로, 캐리어가 positive의 4.56초에 길이를 맞추는 역할을 한다. positive에는 캐리어를 붙이지 않는 대신, 숫자열이 문장 앞·중간·끝에 오도록 설계한 여러 템플릿을 사용하여 발화 내 절대 위치가 단서가 되지 않게 하였다.

캐리어가 hard-negative 쪽에 치우쳐 나타나므로(v2 기준 hard-negative의 87.1%, positive와 easy-negative는 0%) 모델이 “캐리어가 들리면 negative”라는 지름길을 쓸 가능성을 검토해야 한다. 캐리어 유무만으로 판정하는 결정론적 규칙은 두 버전 모두에서 기각된다. 그 규칙이라면 캐리어 없는 hard-negative가 전부 오탐이 되므로 오탐률이 v1에서 $32/300 = 0.107$, v2 평가 분할에서 $24/142 = 0.169$ 로 고정되는데, 실측값은 v1에서 0.006, v2에서 0.415–0.542로 양쪽 다 어긋난다. 특히 v1에서는 세 시드 합계 hard-negative 192개 가운데 캐리어가 없는 것이 20개인데 전체 오탐이 1건뿐이므로, 캐리어 없는 hard-negative도 사실상 전부 기각된다. 즉 캐리어는 기각의 필요조건이 아니다. 다만 캐리어가 여러 특징 가운데 하나의 부분적 단서로 쓰일 가능성까지 배제하려면 캐리어 유무로 나눈 조건부 오탐률의 직접 비교가 필요한데, 클립별 점수를 보존하지 않아 수행하지 못하였다.

(3) 숫자 표기 정규화. 문장에 남아 있는 모든 아라비아 숫자를 한국어 자릿수 발음으로 치환한다(0→공, 1→일, ...). 구분자로 나뉜 그룹은 그룹 단위로 묶어 공백으로 이어 붙인다. 이 단계의 목적은 3.3절에서 상술한다.

(4) 음성 합성과 후처리. 버전 1(v1)은 음성합성(Text-to-Speech, TTS) 도구인 edge-tts의 한국어 신경망 음성 3종(남성 2, 여성 1)으로, 버전 2(v2)는 Qwen3-TTS [20] 기반의 14화자 음성 은행(3.4절)으로 합성한다. v2에서는 화자를 발화 순서에 따라 균등 순환 배정하여 클래스와 화자가 상관되지

않게 하였고(화자별 128–131개), v1에서는 발화마다 세 화자 중 하나를 균등 확률로 무작위 추출하였다(화자별 655–680개). 모든 출력은 16 kHz 모노 PCM16으로 통일하고, 파일별로 텍스트, 값, PII 유형, 화자, 템플릿 식별자, 라벨, 길이를 메타데이터로 기록한다. 생성 난수 시드는 42로 고정하였다(v1 hard-negative만 43).

표 2: 클래스별 생성 문장 예시(템플릿과 값 생성 규칙에 따라 재구성). 원문의 모든 숫자가 자릿수 발음으로 변환되어, 두 클래스가 낭독 방식이 아니라 숫자열 형식에서만 달라진다.

클래스	원문	합성에 사용된 텍스트	라벨
positive (전화)	제 전화번호는 010-1824-0409입니다.	제 전화번호는 공일공 일팔이사 공사 공구입니다.	1
positive (카드)	카드 번호는 4921-3387-0155-2860 입니다.	카드번호는 사구이일 삼삼팔칠 공일 오오 이팔육공입니다.	1
hard-neg (날짜)	오늘은 2026년 3월 25일입니다.	오늘은 이공이육년 삼월 이오일입니 다.	0
hard-neg (주문)	주문번호는 47032918665입니다.	주문번호는 사칠공삼이구일팔육육 오입니다.	0
easy-neg	커피 한잔하면서 잠깐 쉬었다 가시 죠.	(동일)	0

3.3 지름길 단서를 차단하기 위한 통제

합성 데이터는 통제가 쉬운 대신, 설계를 잘못하면 모델이 과제의 본질과 무관한 지름길 단서로 높은 점수를 얻기 쉽다 [6]. 길이 단서에 대한 통제는 3.2절의 캐리어 결합에서 이미 다루었고, 이 절에서는 나머지 세 가지를 기술한다.

읽기 방식 통제. 한국어에서 숫자는 두 가지 방식으로 낭독된다. 하나는 자릿수를 하나씩 읽는 방식(“공일공 일이삼사”)이고, 다른 하나는 수량으로 읽는 방식(“삼만 오천 원”, “이천이십육 년”)이다. 자연스럽게 문장을 합성하면 전화번호와 계좌번호는 자릿수 읽기로, 가격과 날짜는 수량 읽기로 낭독되어 두 클래스의 음소 구성과 운율이 체계적으로 달라진다. 이 상태로 학습하면 모델은 “PII 형식인가”가 아니라 “자릿수 읽기인가”라는 훨씬 쉬운 지름길 단서만으로 두 클래스를 분리할 수 있고, 그렇게 얻은 높은 정확도는 본 연구의 주장을 전혀 뒷받침하지 못한다. 이를 막기 위해 positive와 negative를 가리지 않고 문장 안의 모든 숫자를 자릿수 발음으로 강제 변환하였다. 예컨대 hard-negative의 원문 “오늘은 2026년 3월 25일입니다”는 “오늘은 이공이육년 삼월 이오일입니다”로 합성된다(표 2). 그 결과 두 클래스는 사용하는 음소 목록과 낭독 스타일이 사실상 동일해지고, 남는 차이는 오직 숫자열의 형식, 즉 연속되는 자릿수의 길이와 그룹 경계의 배치뿐이다. 다만 hard-negative의 “수 세기”(“하나 둘 셋 넷 다섯 여섯 일곱”)는 아라비아 숫자를 포함하지 않아 자릿수 변환의 대상이 아니며, 자릿수 낭독이 아닌 고유어 수사가 연속될 때에도 오답이 발생하는지를 보기 위한 별도 조건으로 포함하였다.

hard-negative 설계. negative가 숫자를 포함하지 않는 일반 발화뿐이라면, “숫자 소리가 들리는가”라는 단일 규칙만으로도 높은 정확도가 나온다. 이 경우에도 타당성 주장은 성립하지 않는다. 따라서 숫자를 포함하되 PII가 아닌 발화를 negative의 상당 부분으로 투입하였다. 특히 v2에서는 주문번호를 9–11자리, 제품 일련번호를 4+4+4자리로 설계하여 각각 계좌·전화번호, 카드번호와 자릿수 길이 및 그룹 구조가 의도적으로 충돌하도록 만들었다. 이들 hard-negative는 앞의 읽기 방식 통제에 따라 positive와 동일하게 자릿수로 낭독되므로, “숫자 존재”라는 단서는 두 클래스 사이에서 상수가 된다. 결과적으로 hard-negative에 대한 오탐률(False Positive Rate, FPR)은 모델

이 숫자의 유무가 아니라 형식을 학습했는지를 직접 측정하는 지표가 된다. 형식적으로 이 지표는 $\frac{1}{|H|} \sum_{c \in H} \mathbb{1}[s(c) \geq \tau]$ 로 정의하며 H 는 평가셋의 hard-negative 클립 집합이다. 분모가 negative 전체가 아니라 hard-negative에 한정된다는 점에서 통상의 FPR과 다르며, 본 논문은 이를 주요 지표로 함께 보고한다.

출처 지문 통제. 길이와 녹음 조건이 클래스와 상관되면 그 자체가 단서가 된다. 이를 막기 위해 5초보다 짧은 클립은 무음(진폭 0)이 아니라 진폭 10^{-3} 의 저진폭 노이즈로 패딩하여, 무음 구간의 길이가 원 클립 길이를 그대로 노출하지 않도록 하였다. 또한 v2에서는 세 클래스를 모두 동일한 화자 풀, 동일한 TTS 모델, 동일한 후처리(16 kHz 모노 변환)로 생성하여 코덱 특성이나 화자 지문 같은 출처 단서로 클래스를 구분할 수 없게 하였다.

3.4 화자 은행 구축과 일관성 검증

v2의 14화자를 만들기 위해 Qwen3-TTS의 두 체크포인트를 서로 다른 역할로 사용하였다. 먼저 VoiceDesign 체크포인트(Qwen3-TTS-12Hz-1.7B-VoiceDesign)에 “20대 여성, 매우 높고 밝은 목소리, 빠른 말투, 발랄한 느낌” 같은 한국어 지시문을 주어, 화자마다 고정된 문장 한 개(“안녕하세요, 오늘 하루도 좋은 하루 되시기 바랍니다.”)를 1회씩 합성하고 이를 그 화자의 참조 음성으로 저장하였다. 로스터는 성별 7:7, 연령대 20-60대, 음높이·속도·음색·화풍을 서로 대비되도록 14종으로 설계하였다. 그다음 데이터셋의 1,800개 발화는 모두 Base 체크포인트(Qwen3-TTS-12Hz-1.7B-Base)의 음성 복제(voice clone) 기능으로 합성하였다. 즉 실제 오디오를 만든 모델은 VoiceDesign이 아니라 Base이며, VoiceDesign은 화자 정체성을 정의하는 참조 음성 14개를 만드는 데에만 쓰였다.

이 두 단계 구성을 택한 이유는 6화자 규모의 예비 실험 때문이다. VoiceDesign을 발화마다 직접 호출하면 같은 지시문을 주어도 발화 간 음색 변동이 커서, 화자 임베딩의 코사인 거리로 측정한 화자 간 거리와 화자 내 거리의 비(between/within)가 0.61에 그쳤다. 즉 같은 화자로 지정한 발화들이 다른 화자와의 차이보다 더 크게 흔들려 “화자”라는 변수가 통제되지 않았고, 이 상태의 데이터로는 화자 분리 평가가 무의미해진다. 참조 음성 1개를 고정하고 복제하는 방식으로 바꾸자 화자 내 거리가 0.0377에서 0.0106으로 줄고 화자 간 거리는 유지되어 비율이 2.29로 개선되었다. 여기서 쓴 임베딩은 독립적인 화자 검증 모델 [21]이 아니라 Base 모델이 음성 복제용으로 산출하는 내부 화자 임베딩이므로, 데이터를 만든 모델 자신의 표현으로 확인한 값이다(합성 화자 구성의 한계는 7장).

3.5 데이터셋 통계

표 3에 두 버전의 구성을 정리하였다. v1은 전화번호 단일 유형에 대한 통제 실험용이고, v2는 PII 유형과 화자를 함께 확장한 일반화 실험용이다. 클립 길이는 v2 기준 positive 중앙값 4.56초, hard-negative 4.64초, easy-negative 3.28초로 클래스 간 큰 편차가 없으며, 길이 단서의 영향은 5장의 length-matched 평가로 별도 검증한다.

v1은 negative의 대부분이 어떤 형태로든 숫자를 포함하는, 설계 의도보다 오히려 더 까다로운 조건에서 평가되었다. easy-negative로 재사용한 일반 발화 코퍼스(고유 문장 331종) 가운데 283종이 “오늘은 육삼팔번 버스를 이용하고”처럼 자릿수로 낭독되는 짧은 숫자 표현을 포함하기 때문이다. 따라서 “숫자 존재” 단서를 두 클래스 사이에서 상수로 만든다는 3.3절의 통제 취지는 v1에서 더 강하게 성립한다. v2의 easy-negative는 숫자를 전혀 포함하지 않는 12종 문장으로 새로 생성하였다.

표 3: 데이터셋 구성. v2의 positive는 네 PII 유형에 225개씩 균등 배분되었다.

버전	TTS	화자	PII 유형	positive	hard-neg	easy-neg	합계
v1 (controlled)	edge-tts	3	전화	1,000	300	700	2,000
v2	Qwen3-TTS	14	전화·주민·계좌·카드	900	450	450	1,800

3.6 윤리적 고려와 데이터 품질

본 연구에 사용된 모든 음성은 TTS로 합성한 것이며 실제 인물의 음성을 포함하지 않는다. 발화에 등장하는 전화번호, 주민등록번호, 계좌번호, 카드번호는 형식만 맞춘 난수로, 실재하는 개인의 정보가 아니다. 따라서 데이터 수집 단계에서 개인정보가 처리되지 않았다. 품질 측면에서는, v2 생성 과정에서 TTS가 비정상적으로 반복 생성한 클립 2개(모두 negative, 길이 655초)가 포함되어 있음을 확인하였다. 평가 시 클립 점수를 원도 최댓값으로 집계하므로 이런 초장 클립은 오답 확률을 높이는 방향으로만 작용하며, 결과를 낙관적으로 왜곡하지 않는다.

4 방법

4.1 특징 추출과 원도 전략

16 kHz 모노 오디오를 로그 멜 스펙트로그램으로 변환한다(멜 채널 64, 고속 푸리에 변환(Fast Fourier Transform, FFT) 크기 1024, hop 512, power 2.0). 진폭은 원도 내 최댓값을 기준으로 데시벨로 변환한 뒤 원도별로 평균 0, 표준편차 1로 정규화하여 클립 간 음량 차이를 제거한다. 5초 원도는 64×157 크기의 특징이 된다. 학습 시에는 클립에서 5초 구간을 무작위로 잘라내되 클립이 5초보다 짧으면 저진폭 노이즈로 패딩하는 대신 random-crop을 쓰고, 평가 시에는 2.5초 간격의 sliding window로 클립 전체를 덮은 뒤 원도별 점수의 최댓값으로 클립 점수를 집계한다. 학습과 평가에서 원도 사용 방식이 다른 이유는, 학습에서는 위치 다양성을 통한 증강 효과가 필요하고 평가에서는 클립 어디에 숫자열이 있는 놓치지 않아야 하기 때문이다. 학습 원도에는 클립 라벨을 그대로 부여하므로, 5초를 넘는 positive 클립에서는 숫자열이 잘려 나간 원도가 positive로 학습될 수 있다. 그림 2는 positive와 hard-negative의 멜 스펙트로그램 예시로, 자릿수로 낭독되는 숫자열이 규칙적인 세로 줄무늬 텍스처로 나타남을 보여준다.




그림 2: 멜 스펙트로그램 예시. v2 데이터의 네 클립(전화번호 positive, 주민등록번호 positive, hard-negative 숫자열, 숫자 없는 일반 발화)의 첫 5초 원도를 모델 입력과 동일하게 변환한 것이다(멜 채널 64, 원도별 표준화 후의 값). 자릿수로 낭독되는 PII 형식 숫자열은 규칙적인 시간-주파수 패턴(세로 줄무늬)으로 나타난다. 이 네 클립을 학습에서 제외한 뒤 실제로 추론했을 때 모델이 부여한 PII 확률은 각각 0.973, 0.989, 0.107, 0.030으로 네 건 모두 정답이었으므로, 그림의 텍스처 차이는 사후 해석이 아니라 모델의 판정과 일치한다.

4.2 모델과 비교군

직접 설계한 `simple_cnn`은 3×3 합성곱-배치정규화-ReLU-맥스풀 4블록 (채널 $16 \rightarrow 32 \rightarrow 64 \rightarrow 64$) 뒤에 전역 평균 풀링, 드롭아웃 (0.3), 선형 분류기를 둔 60,706 파라미터 모델이다. 전역 평균 풀링을 사용하므로 시간축 위치에 대해 평행이동 불변에 가깝고, 숫자열이 원도 안 어디에 놓이든 같은 특징이 활성화된다. 비교군으로는 ImageNet에서 사전학습된 MobileNetV3-Small [22], EfficientNet-B0 [23], ConvNeXt-Tiny [24]를 사용한다. 이들은 3채널 입력을 요구하므로 1채널 멜 스펙트로그램을 3채널로 복제하여 넣고 분류기 헤드만 2클래스로 교체하였으며, 계층 동결이나 차등 학습 없이 전 계층을 `simple_cnn`과 동일한 설정으로 미세조정하고, 입력 정규화도 ImageNet 통계가 아닌 원도별 표준화를 그대로 사용하였다.

표 4: 데이터 분할 구성 (seed 42). v2의 test(=v2-HN)에 easy-negative가 없는 것은 easy-negative 450개가 하나의 템플릿 그룹으로 묶여 학습 분할에 배정되었기 때문이다. v1의 train/val 클래스 분해는 학습 로그에 남지 않아 표시하지 않았다. v1 전체 구성 (positive 1,000 / hard-negative 300 / easy-negative 700)에서 test를 빼면 train과 val을 합한 구성은 827 / 238 / 604이다.

	v1 합계	v1 (positive/hard/easy)	v2 합계	v2 (positive/hard/easy)
train	1,343	—	1,165	539 / 176 / 450
val	326	—	304	172 / 132 / 0
test	331	173 / 62 / 96	331 (v2-HN)	189 / 142 / 0

4.3 데이터 분할

분할은 클립 단위가 아니라 문장 템플릿 단위로 수행한다. 같은 템플릿에서 파생된 클립들은 숫자 값만 다르고 캐리어 문장과 어순이 동일하므로, 이들이 학습과 평가에 나뉘어 들어가면 모델이 템플릿 자체를 외워 점수가 부풀려진다. 따라서 각 `template_id`를 하나의 그룹으로 묶어 통째로 한 분할에만 배정한다(template-disjoint). 목표 비율은 70/15/15이며, 라벨별로 목표량을 따로 채워 클래스 균형을 유지한다(label-stratified). 배정 순서는 그룹의 평균 길이 오름차순으로 하고, 매 그룹마다 현재 채움 비율 `cur/target`이 가장 작은 분할에 배정한다. 이렇게 하면 세 분할이 길이 스펙트럼의 전 구간을 고르게 나눠 갖게 되어(length-stratified), 길이 분포가 분할 간에 어긋나 길이 단서 통제가 무의미해지는 상황을 방지한다. test 분할은 학습, 하이퍼파라미터 선택, 조기 종료, 임계값 결정 어디에도 사용하지 않는다.

임계값 결정 규칙은 목적에 따라 셋으로 나뉜다. 첫째, 5장의 메인 성능표와 통제 평가는 튜닝 없이 고정 임계값 0.5를 사용한다. 둘째, LOSO의 튜닝 임계값은 각 폴드의 검증 분할에서 F1을 최대화하는 값을 0.05부터 0.95까지 0.05 간격의 19개 후보 중에서 고른 것이다. 셋째, 프리필터 운용표의 임계값은 검증 분할 positive 확률 분포에서 목표 재현율에 해당하는 분위수로 정한다. 세 규칙 모두 test를 참조하지 않는다. 또한 v1의 Original 평가셋(통제 이전 데이터)은 controlled 학습 분할에 포함된 파일을 제외한 뒤 사용하여, 두 manifest가 같은 원본 파일을 공유하면서 생기는 누수를 차단하였다.

표 4는 실제 분할 결과이다. v1은 seed 42 기준 1,343/326/331로 나뉘었고, test는 positive 173, hard-negative 62, easy-negative 96으로 구성된다. v2에서는 템플릿 그룹화가 평가 분할의 구성을 결정한다. easy-negative 450개는 모두 하나의 템플릿 식별자를 공유하여 한 덩어리로 학습 분할에 배정되었고, hard-negative는 템플릿 식별자가 생성 카테고리 이름이어서 카테고리 단위로 배정되었다. 그 결과 v2의 test는 positive 189개와 hard-negative 142개로만 이루어지며, hard-negative는 수세기(52), 주문번호(45), 좌석번호(45) 세 카테고리로 구성된다. 이하에서는 이 분할을 **v2-HN**(hard-negative 스트레스 셋)이라 부른다. positive도 유형별 템플릿 인덱스로 묶여 전화번호 템플릿이 전부 학습·검증으로 배정되었으므로, v2-HN의 positive는 카드 81개, 계좌 56개, 주민 52개이다.

이 구성은 두 가지 성질을 갖는다. 하나는 val과 test의 hard-negative 카테고리가 서로 겹치지 않는다는 것으로, val에서 고른 임계값은 학습·검증에서 한 번도 보지 못한 종류의 비PII 숫자열에

이식된 값이 된다(5장에서 정량 확인). 다른 하나는 v2-HN에 남은 세 카테고리 중 주문번호가 계좌·전화와 형식이 가장 심하게 충돌하는 유형이라는 것으로, v2-HN에서 측정한 hard-negative FPR은 충돌 난이도가 높은 쪽으로 치우친 값이다. 따라서 v2-HN의 정밀도와 오탐률은 비관적 하한, easy-negative를 함께 포함한 v1의 값은 낙관적 상한으로 읽는 것이 타당하며, 두 버전의 차이는 “숫자 유무”가 아니라 “PII와 형식이 충돌하는 긴 연속 숫자열의 비중”에 있다.

4.4 학습 설정

최적화는 AdamW [25](학습률 1×10^{-4} , weight decay 1×10^{-4}), 손실은 클래스 가중치를 주지 않은 교차엔트로피, 배치 크기는 32, 최대 에폭은 50(v2 일반화 실험은 40)이며, 학습률은 cosine annealing [26]으로 감쇠시킨다. v1은 positive와 negative가 1:1로 균형 잡혀 있고, v2의 train은 positive 539 대 negative 626으로 약간 기울어져 있다(표 4). 매 에폭이 끝나면 검증 분할 전체를 클립 단위로 추론하여 고정 임계값 0.5에서 F1을 계산하고, 8에폭 동안 개선이 없으면 조기 종료한 뒤 검증 F1이 가장 높았던 시점의 가중치를 복원한다. 데이터 증강으로는 학습 시의 random-crop에 더해 보수적인 SpecAugment [27]를 적용하여, 주파수 마스크 1개(최대 8개 멜 채널)와 시간 마스크 1개(최대 16프레임)를 정규화 후 평균값에 해당하는 0으로 채운다. 데이터로더는 학습 시 셔플과 작업자 4개를 사용하고, 평가 시에는 클립 하나의 모든 윈도를 한 배치로 처리한다. 실험은 NVIDIA A100-SXM4-40GB 단일 GPU에서 수행하였고, 조기 종료로 simple_cnn은 시드별 30–42에폭, 사전학습 백본은 10–35에폭에서 학습이 종료되었다.

표기 규약은 다음과 같다. v1의 메인 실험과 기준선은 시드 42, 43, 44로 3회 반복하므로 v1의 $\pm$ 는 시드 간 표준편차이다. 시드는 가중치 초기화와 증강 난수뿐 아니라 easy-negative 표본추출과 분할 시 그룹 셔플의 tie-break에도 영향을 주므로, 시드마다 평가셋 구성이 조금씩 달라진다(v1 test는 331–339개). v2의 in-distribution 성능, LOSO, held-out-PII, 보정 분석은 계산 비용 때문에 시드 42 단일 학습으로 수행하였고, 따라서 v2의 $\pm$ 는 화자 폴드 간 표준편차를 뜻한다.

출처를 명확히 하기 위해 한 가지를 덧붙인다. 학습 스크립트는 파이썬과 PyTorch의 전역 시드를 고정하지만 cuDNN 결정성 옵션과 데이터로더 작업자 시드를 강제하지 않으므로, 동일 시드로 재학습해도 결과가 비트 단위로 일치하지 않는다. v2-HN 설정을 세 차례 독립 재학습한 결과 고정 임계값 0.5에서의 hard-negative FPR은 0.415, 0.493, 0.542였다. 표 9와 그림 5, 그리고 STT+NLP와의 유형별 비교는 세 번째 실행(0.542)에서, 표 8의 운용점과 6장의 보정 분석은 두 번째 실행(0.493)에서, 그림 6의 카테고리 분해는 첫 번째 실행(0.415)에서 얻은 것이다. 표 7의 “학습에 포함 시” 열도 세 번째 실행의 값이다. 같은 세 실행에서 PII 유형별 재현율도 주민번호 0.865–0.962, 계좌 0.982–1.000의 변동을 보였으므로, v2의 단일 실행 수치는 이 폭의 불확실성을 갖는다.

4.5 기준선

CNN이 학습을 했다고 주장하려면 최소한 다음 세 기준선을 넘어야 한다. (i) 학습 분할의 다수 클래스를 상수로 예측하는 majority. v1은 두 클래스가 1:1로 균형 잡혀 있어 다수 클래스가 동물이며 구현상 negative가 선택되므로, 재현율과 F1이 0이 된다. 이 기준선은 성능 하한이라기 보다 평가셋의 클래스 사전확률을 드러내는 참조점이며, 표 5의 PR-AUC 0.516이 곧 controlled 평가셋의 positive 비율에 해당한다. (ii) 클립 길이 하나만을 특징으로 쓰는 duration-only 로지스틱 회귀. (iii) 클립 전체에서 계산한 수작업 음향 통계 7개를 특징으로 쓰는 acoustic-LR 로지스틱 회귀이며, 특징은 클립 길이, 제곱평균제곱근(Root Mean Square, RMS) 에너지의 평균·표준편차, 영교차율의 평균·표준편차, 스펙트럼 중심의 평균·표준편차이다. 두 회귀 모두 표준화 후 L2 정규화 로지스틱 회귀에 입력한다. duration-only는 길이 단서만으로 과제가 풀리는지를, acoustic-LR는 길이에 시간 평균된 전역 음향 통계를 더해 프레임 간 시간 구조 없이는 풀리지 않음을 각각 측정한다.

4.6 평가 지표와 평가셋

지표는 F1, 재현율, 정밀도, ROC 곡선 아래 면적(Area Under the Receiver Operating Characteristic curve, ROC-AUC), 정밀도-재현율 곡선 아래 면적(Area Under the Precision-Recall curve, PR-AUC), hard-negative FPR, 추론 지연이다. 지연은 배치 크기 1로 64×157 무작위 입력을 워밍업 10회 뒤 50회 순전파한 평균이며, 멜 스펙트로그램 추출과 오디오 디코딩 시간은 포함하지 않는다.

평가셋은 test 분할에서 조건별로 파생한 다섯 가지를 사용한다. `controlled_main`은 test 분할 그대로이고, `length_matched`는 positive의 길이 히스토그램을 10개 구간으로 나눈 뒤 각 구간에서 같은 수의 negative를 표본추출하여 두 클래스의 길이 분포를 맞춘 것이며, `hard_negative_only`는 easy-negative를 제거하고 positive와 hard-negative만 남긴 가장 어려운 조건이다. `stress_5_5`는 negative 내부의 easy:hard 비율을 1:1로 재가중한 것으로, positive:negative 균형이 깨지므로 임계값에 독립적인 지표 중심으로 해석한다. `original`은 통제를 적용하기 이전의 데이터로, 누수 파일을 제외한 뒤 통제 설계의 필요성을 확인하는 데 사용한다.

4.7 일반화 평가 절차

화자 일반화는 leave-one-speaker-out(LOSO)으로 측정한다. 화자 한 명의 모든 클립을 test로 고정하고 나머지 화자의 클립을 template-disjoint로 나누어 학습과 검증에 쓰며, 검증 분할에서 임계값을 튜닝하여 고정 임계값 0.5와 비교한다. v1은 화자 3명과 시드 3회를 조합한 9회, v2는 화자 14명에 대해 시드 42로 14회 수행하였다.

PII 유형 일반화는 held-out-PII 절차로 측정한다. 특정 유형(예: 주민등록번호)의 positive를 학습 풀에서 완전히 제거한 뒤 나머지 positive와 전체 negative로 모델을 학습하고, 제외했던 유형의 positive 225개 전부에 대해 재현율을 측정한다. 평가대상 유형의 positive는 학습 중 한 번도 등장하지 않으므로, 이 절차가 검증하는 것은 미학습 유형에 대한 재현율이다. 반면 이 절차는 negative 전량을 학습 풀에 넣은 뒤 그 일부를 평가에 재사용하므로 negative 쪽 지표(정밀도, overall F1, ROC-AUC)는 낙관적으로 편향된다. 따라서 이들 지표는 보고하지 않으며, negative 쪽 비용은 누수가 없는 5장의 v2-HN hard-negative FPR을 참고값으로 삼되 학습 유형 구성이 다른 별개 조건임에 유의한다.

4.8 STT+NLP 비교 경로의 구성

표준 경로는 Whisper-large-v3 [4]로 클립을 전사한 뒤(fp16, 30초 청크, 배치 16) 규칙 기반 탐지기를 적용하여 구성하였다. Whisper는 한국어 자릿수 발음을 대체로 아라비아 숫자로 정규화하지만 그룹 구분자는 발화 휴지에 따라 임의로 삽입하므로, 탐지기는 하이픈, 공백, 쉼표, 마침표를 무시하고 인접한 숫자들을 하나의 숫자열로 묶은 뒤 그 길이와 선두 패턴으로 유형을 판정한다(11자리이면서 “01”로 시작하면 전화, 13자리면 주민등록번호, 16자리면 카드, 10-14자리면 계좌). 이를 “형식만” 변형이라 한다. “형식+문맥” 변형은 여기에 문맥 키워드를 결합하여, 형식이 일치하더라도 “주문번호”, “송장”, “우편번호”, “좌석”, “일련번호” 같은 비PII 키워드가 있고 PII 키워드가 없으면 negative로 되돌린다. 두 변형 모두 CNN과 동일한 test 분할(v2-HN, $n = 331$)에서 동일한 지표로 평가하였다.

5 실험 및 결과

5.1 타당성: 기준선 초과 (RQ1)

표 5에서 `simple_cnn`은 $F1 = 0.955 \pm 0.010$, $ROC-AUC = 0.997 \pm 0.001$ 로 최고 성능의 기준선 acoustic-LR(0.761 / 0.878)을 크게 능가하였다. duration-only가 ROC-AUC 0.701에 그친 점은 길이 단서만으로는 과제가 풀리지 않음을, acoustic-LR가 0.878에 그친 점은 길이를 포함한 전역 음향 통계로도 한계가 있음을 보인다. CNN이 이를 능가한다는 것은 전역 통계로 포착되지 않는 시간-주파수 패턴을 학습했음을 시사한다.

표 5: 메인 성능 (v1 controlled 평가셋, 시드 42/43/44 평균±표준편차, 임계값 0.5). 평가셋은 v1 test 분할 전체 ($n = 331\text{--}339$, 시드에 따라 다름)이며 클립 단위로 판정한다. CNN 계열은 2.5초 간격 sliding window 확률의 최댓값을 클립 점수로 쓰고, 세 기준선은 클립 전체에서 계산한 특징을 사용한다. Hard-neg FPR은 hard-negative 클립(시드당 58–72개)만을 분모로 하는 오탐률이며, ROC-AUC와 PR-AUC는 시드 평균값이다.

모델	F1	Recall	Precision	Hard-neg FPR	ROC-AUC	PR-AUC
majority (기준선)	0.000	0.000	—	0.000	0.500	0.516
duration-only (기준선)	0.633	0.630	0.635	0.812	0.701	0.638
acoustic-LR (기준선)	0.761	0.703	0.832	0.264	0.878	0.884
simple_cnn	0.955 ± 0.010	0.927 ± 0.028	0.986 ± 0.011	0.006 ± 0.008	0.997	0.998
mobilenet_v3_small	0.776 ± 0.011	0.642 ± 0.012	0.982 ± 0.014	0.021 ± 0.015	0.945	0.954
efficientnet_b0	0.867 ± 0.010	0.771 ± 0.024	0.991 ± 0.013	0.011 ± 0.016	0.994	0.994
convnext_tiny	0.804 ± 0.132	0.703 ± 0.172	0.959 ± 0.058	0.056 ± 0.079	0.962	0.960

5.2 지름길 단서 통제 (RQ2)

길이 단서. duration-only 기준선은 length-matched 평가셋에서 ROC-AUC가 $0.701 \rightarrow 0.534$ (우연 수준)로 붕괴하고 hard-negative의 90.7%를 positive로 오판하지만, CNN은 같은 평가셋에서 F1이 controlled와 사실상 동일하고(0.956 ± 0.011 대 0.955 ± 0.010) hard-negative 오탐은 세 시드 모두 0 건이었다(0.000 ± 0.000).

숫자 존재 대 형식. 날짜, 주문번호, 가격 등 비PII 숫자열에 대한 오탐률이 0.006 ± 0.008 로 매우 낮아, 모델은 “숫자가 들린다”가 아니라 “전화번호 형식”을 구분한다. negative를 hard-negative로만 좁힌 가장 어려운 조건에서 이 대비는 오히려 더 뚜렷해진다. 이 평가셋에서 CNN의 정밀도는 0.998 ± 0.003 , ROC-AUC는 0.9992 ± 0.0006 , PR-AUC는 0.9997 ± 0.0002 로 다섯 평가셋 가운데 가장 높았던 반면, duration-only 기준선의 ROC-AUC는 0.394로 우연 수준 아래까지 떨어졌다. 길이 정렬을 위해 붙인 캐리어 문장 때문에 hard-negative가 오히려 positive보다 길어져 길이 단서가 역방향으로 작동하기 때문이다. easy:hard 비율을 1:1로 올린 stress 조건에서도 CNN의 F1은 0.958 ± 0.012 , ROC-AUC 0.998로 변하지 않았다. 즉 평가조건을 어렵게 만들수록 지름길 기준선은 무너지고 CNN은 유지된다.

이 통제가 형식적 절차가 아니었음은 통제 이전 데이터(original 평가셋)와 비교하면 분명해진다. 통제를 적용하지 않은 데이터에서는 클립 길이 하나만 쓰는 duration-only 기준선이 $F1 = 0.956$, $ROC-AUC = 0.989$ 로 사실상 과제를 완전히 풀어 버리며, 같은 데이터에서 60,706 파라미터 CNN이 얻은 ROC-AUC 0.968보다도 높다. 반면 길이 외의 전역 음향 통계에 의존하는 acoustic-LR는 통제 전 0.876과 통제 후 0.878이 사실상 같아, 통제로 제거된 것이 정확히 길이 축임을 보여준다. 낭독 방식 통제와 hard-negative 투입이 없었다면 본 연구가 보고하는 높은 성능은 전부 길이 단서로 설명될 수 있었고, 통제 이후의 수치만이 “형식을 학습했다”는 주장을 지지한다.

5.3 모델 규모: 경량 모델의 우위 (RQ5)

네 모델은 검증 성능에서는 구분되지 않는다. simple_cnn, EfficientNet-B0, ConvNeXt-Tiny는 세 시드 대부분에서 검증 F1 1.000에 도달했고 MobileNetV3-Small도 0.962–0.991을 기록했다. 그럼에도 test F1은 0.776에서 0.955까지 벌어지므로, 격차는 학습 데이터를 맞추는 능력이 아니라 처음 보는 템플릿으로의 일반화에서 발생한다. ConvNeXt는 두 번째 예폭에 이미 검증 F1 1.000에 도달하고 10예폭에서 조기 종료되었는데도 test F1은 0.804 ± 0.132 에 그쳤다. 임계값에 독립인 PR-AUC로 비교해도 simple_cnn의 0.998이 ConvNeXt의 0.960 ± 0.050 과 MobileNetV3의 0.954를 앞선다. 지연 측면에서는 모바일 배포를 겨냥해 설계된 MobileNetV3-Small보다도 5.9배 빠르다(0.34ms 대 2.03ms). 요컨대 60,706 파라미터 모델이 약 460배 큰 27.8M ConvNeXt-Tiny를 일반화, PR-AUC, 지연 세 축 모두에서 능가하였다(그림 3, 표 6).

원인으로는 네 가지를 생각할 수 있으나 근거의 강도는 서로 다르다. 실험으로 직접 관측된 것은

(1) 소량 데이터($\sim 2,000$)에서 대형 모델의 학습이 불안정해진다는 점으로, ConvNeXt만 시드에 따라 F1이 0.635, 0.819, 0.958로 흔들려 표준편차 ± 0.13 을 보인 반면 나머지 세 모델은 ± 0.01 수준이었다. (2) ImageNet(자연 사진)과 멜 스펙트로그램의 도메인 불일치, (3) 저수준 음향 패턴으로 풀리는 과제의 단순성, (4) 작은 용량에 의한 암묵적 정규화는 해석적 가설이며, 이를 가르려면 무작위 초기화 백본과 사전학습 백본의 대조 및 용량 스위치가 필요하다. 본 비교는 네 모델에 동일한 학습률, 에폭, 배치 크기를 적용했으므로 결론은 “동일 예산·동일 설정에서는 경량 전용 CNN이 더 나은 선택”이라는 형태로 읽어야 한다.




그림 3: 파라미터 수(로그) 대 controlled F1(시드 3회 평균). 60K 자작 CNN이 27.8M ImageNet 백본을 능가한다.

표 6: 모델 효율성 비교. 파라미터는 학습 가능 파라미터 총수, 크기는 저장된 체크포인트 파일 용량, 지연은 NVIDIA A100 40GB에서 배치 크기 1로 64×157 입력을 워밍업 10회 뒤 50회 순전파한 평균(멜 스펙트로그램 추출 시간 제외)이다.

모델	파라미터	크기(MB)	GPU ms/window
simple_cnn	60,706	0.26	0.34
mobilenet_v3_small	1,519,906	6.21	2.03
efficientnet_b0	4,010,110	16.34	2.92
convnext_tiny	27,821,666	111.35	2.32

5.4 화자 일반화: LOSO (RQ3)

미학습 화자에 대한 순위 성능은 v1의 아홉 폴드 전부에서 ROC-AUC 0.97 이상 (0.992 ± 0.008)이었고, negative를 hard-negative로만 좁혀도 아홉 폴드 전부 0.98 이상(0.996 ± 0.004)을 유지하였다. 재현을 역시 아홉 폴드 중 여섯(Hyunsu·SunHi의 세 시드 전부)에서 정확히 1.000이었다. 즉 형식 신호 자체는 처음 보는 화자에게도 일관되게 일반화된다.

고정 임계값 0.5에서 집계한 F1은 0.616 ± 0.280 으로 낮아 보이지만, 이는 판별 실패가 아니라 임계값 오프셋 때문이다. 평균을 끌어내린 InJoon 폴드는 세 시드 모두 재현율이 0.068–0.175로 낮은 대신 정밀도가 1.000이었고, 임계값을 0.2에서 0.8까지 옮겨도 hard-negative 오탐이 단 한 건도 발생하지 않았다. 이 폴드의 문제는 오분류가 아니라 점수 분포 전체가 아래로 이동한 것이다. 다만 v1에서는 세 화자를 동시에 만족시키는 단일 임계값이 없다. $\tau = 0.8$ 에서 Hyunsu 폴드가 F1 0.957–0.982로

오르는 동안 InJoon 폴드는 0.006–0.074로 붕괴한다. 화자 수를 늘렸을 때 얻는 이득은 바로 이 지점에 있다.

화자를 3명에서 14명으로 늘리자 고정 임계값 기준 F1이 0.861 ± 0.102 로 오르고 폴드 간 표준편차가 3분의 1로 줄었다(그림 4 좌). 분포로 보면 성과가 더 분명하다. 14개 폴드의 F1 중앙값은 0.904로 아홉 폴드가 0.87 이상이고, 재현율 중앙값은 0.977에 다섯 폴드가 정확히 1.000이며, ROC-AUC는 열 폴드가 0.95 이상이다(그림 4 우). 평균을 끌어내리는 것은 재현율이 낮은 두 폴드(S13 0.438, S11 0.531)이다. 운용 관점에서 더 중요한 것은 폴드별로 검증셋에서 다시 고른 임계값이 0.25–0.55(평균 0.461)의 좁은 구간에 모두 모였고, 그 임계값을 쓴 평균 F1 0.855 ± 0.094 가 고정 임계값 0.5의 0.861 ± 0.102 와 사실상 같다는 점이다. 화자가 바뀌어도 운용점을 다시 맞추실 필요가 없다는 뜻이다. 다만 v1과 v2는 화자 수 외에 TTS 엔진과 PII 유형 수도 함께 달라졌으므로, 화자 수의 순효과를 분리하려면 동일 데이터에서 학습 화자 수만 바꾸는 실험이 필요하다.




그림 4: 화자 분리(LOSO) 일반화(임계값 0.5, v1 9폴드·v2 14폴드). 화자 확장으로 평균 F1이 오르고 폴드 간 분산이 줄어 고정 임계값 운용이 안정화된다.

5.5 PII 유형 일반화: held-out-PII (RQ3)

각 PII 유형을 학습에서 완전히 제외하고 그 유형의 positive 225개 전부로 평가했을 때, 세 유형 모두 학습 없이 재현율 0.88–0.98을 얻었다(표 7). 같은 유형을 학습에 포함했을 때의 재현율도 실험 간 변동을 감안하면 0.87–1.00 범위이므로, 유형을 통째로 빼도 재현율이 그 범위 아래로 떨어지지 않는다. 이는 모델이 특정 숫자열을 암기한 것이 아니라 “PII 형식”이라는 공통 신호를 유형을 넘어 일반화함을 보여주는 가장 직접적인 증거이다. 특히 학습 중 13자리 주민등록번호를 한 번도 보지 못한 모델이 그 유형의 97.8%를 검출한다는 사실은, 판별 근거가 유형별 자릿수 패턴의 암기가 아니라 “자릿수로 낭독되는 긴 숫자열”이라는 상위 규칙임을 시사한다.

표 7: held-out-PII 일반화(v2, simple_cnn, 시드 42, 임계값 0.5). 각 행은 해당 PII 유형의 positive를 학습에서 완전히 제외한 뒤 그 유형의 positive 225개 전부에 대해 측정한 재현율이다. 오른쪽 열은 같은 유형이 학습에 포함되었을 때 v2-HN에서 측정한 재현율(재학습 실험 3)로, 전화번호는 v2-HN에 positive가 남지 않아 비교 대상이 없다. 이 열은 단일 실험 값이며 같은 설정의 다른 실험에서 주민번호 재현율이 0.865까지 변동하므로, 좌우 열의 차이는 실험 간 변동 범위 안에 있다.

제외한 PII	held-out n	held-out recall@0.5	(참고) 학습에 포함 시 recall
주민번호 (rrn)	225	0.978	0.962 ($n = 52$)
카드 (card)	225	0.911	1.000 ($n = 81$)
계좌 (account)	225	0.884	1.000 ($n = 56$)

5.6 프리필터 가치

프리필터의 목적은 목표 재현율을 지키면서 STT 호출을 줄이는 것이다. v1 평가셋에서는 고정 임계값 0.5에서 이미 재현율 0.927, 정밀도 0.986을 유지하며 STT 호출을 51.5% 줄일 수 있고, 임계값을 0.3으로 낮추면 재현율 0.994에서 44.9%, 0.2에서는 재현율 0.998(세 시드 중 둘은 정확히 1.000)에서 41.6%를 절감한다. 반대로 임계값을 0.7로 올리면 세 시드 모두 정밀도 1.000과 hard-negative 오탐 0건을 유지한 채 평균 62%를 절감하지만, 재현율이 0.728로 떨어져 PII의 27%를 놓친다. 프리필터로서 실제로 쓸 수 있는 구간은 재현율을 지키는 저임계값 쪽이며, 그 구간에서 41–45%의 절감이 확보된다.

숫자를 포함한 발화만으로 구성된 v2-HN에서도 임계값 0.31에서 재현율 0.995를 유지하며 STT 호출을 약 16% 줄일 수 있다(표 8). 주목할 점은 이 임계값들이 모두 검증 분할의 확률 분위수만으로 정해졌고 test를 참조하지 않았음에도 목표를 초과 달성했다는 것이다. 목표 재현율 0.99에 해당하는 임계값 0.19가 test에서 재현율 1.000을, 0.95 목표가 0.995를 달성하였다. 4.3절에서 밝혔듯 val과 test의 hard-negative 카테고리는 서로 겹치지 않는다. 이 성질은 의도한 설계가 아니라 템플릿 그룹화가 낳은 부작용이지만, 결과적으로 운용점이 학습·검증에서 한 번도 보지 못한 종류의 비PII 숫자열에 대해서도 이식됨을 보여준다. 다만 임계값의 시드 간 변동은 작지 않아 v1에서 같은 임계값 0.3의 hard-negative 오탐률이 0.016–0.138 범위를 보였으므로, 프리필터 임계값은 배포 시점의 검증 데이터에서 다시 정하는 것이 안전하다.

표 8: 프리필터 운용점 (v2-HN, simple_cnn, 시드 42, 재학습 실행 2). 각 행의 임계값은 검증 분할에서 목표 재현율에 해당하는 분위수로 정한 값이다. STT 호출률은 클립 점수가 임계값 이상이어서 후단 STT로 넘어가는 클립의 비율이며 1 – 호출률이 절감률이다. v2-HN은 숫자가 없는 easy-negative를 포함하지 않으므로, 여기의 호출률은 모든 입력이 숫자를 포함하는 트래픽을 가정한 값이다.

목표 재현율	임계값	Recall	Precision	Hard-neg FPR	STT 호출률
0.99	0.19	1.000	0.663	0.676	0.861
0.95	0.31	0.995	0.679	0.627	0.837
0.90	0.49	0.968	0.723	0.493	0.764

5.7 CNN 대 STT+NLP (RQ4)

동일 인스턴스(v2-HN, $n = 331$)에서 두 접근을 비교하면 강점이 뚜렷하게 갈린다(표 9, 그림 5). CNN은 재현율 0.989와 약 1,000배 빠른 지연으로, STT+NLP(형식+문맥)는 정밀도 0.951로 각각 앞선다. 문맥 단서(선행 단어 “주문번호”, “계좌번호”)를 결합하면 STT+NLP의 hard-negative FPR이 0.218 → 0.063으로 크게 줄어, CNN이 못 풀던 형식 충돌 문제를 문맥이 해결함을 보인다.

유형별로 나누면 상보성이 더 선명해진다(표 10). 카드번호(16자리)에서 STT+NLP는 81개 중 69개만 검출하여 재현율 0.852에 그친 반면 CNN은 81개 전부를 검출하였고, 계좌번호도 CNN 1.000 대 STT+NLP 0.946이었다. 반대로 주민등록번호는 STT+NLP가 52개 전부를, CNN이 50개를 검출하였다. 즉 CNN이 우위를 보이는 지점은 정확히 전사가 구조적으로 취약한 긴 연속 숫자열이며, 이는 두 경로를 직렬로 결합할 근거가 된다.

이 비교에서 STT+NLP 쪽 조건도 밝혀 둔다. 합성음에서는 Whisper 전사가 거의 완벽하여(일반 발화 450개 기준 WER 중앙값 0, 완전일치 80.2%) STT+NLP 성능은 best-case 상한이다. 다만 이 최상 조건에서도 완전일치하지 않은 클립이 19.8%였고 반복 루프 형태의 환각이 1건 발생하여 평균 WER은 0.722까지 올라간다. 중앙값이 0이라는 사실은 전사 오류가 사라졌다는 뜻이 아니라 소수 구간에 집중되어 있다는 뜻이며, 그 소수 구간이 하필 긴 숫자열이라는 점이 카드번호 재현율 0.852로 나타난다. 실통화(잡음, 억양, 코텍)에서는 WER이 상승하지만 깨끗한 합성음으로만 학습한 CNN도 함께 열화하므로, 격차의 방향은 실데이터 평가 없이 예단할 수 없다.

표 9: CNN 대 STT+NLP (v2-HN, $n = 331$, 임계값 0.5, 재학습 실행 3). 지연은 NVIDIA A100 40GB 기준으로 CNN이 배치 1의 윈도우당 순전파 시간(전처리 제외), STT+NLP가 클립 16개를 한 배치로 전사한 시간을 클립 수로 나눈 값이다.

접근	F1	Recall	Precision	Hard-neg FPR	지연
CNN (음향)	0.826	0.989	0.708	0.542	0.344 ms
STT+NLP (형식만)	0.883	0.921	0.849	0.218	~360 ms
STT+NLP (형식+문맥)	0.935	0.921	0.951	0.063	~360 ms

표 10: PII 유형별 재현율 (v2-HN의 동일 positive 인스턴스, 임계값 0.5). CNN은 전사가 취약한 긴 연속 숫자열에서, STT+NLP는 짧고 문맥 키워드가 뚜렷한 유형에서 각각 앞선다.

PII 유형	자릿수	n	CNN (음향)	STT+NLP (형식+문맥)
카드 (card)	16	81	1.000	0.852
계좌 (account)	11-12	56	1.000	0.946
주민번호 (rrn)	13	52	0.962	1.000




그림 5: 재현율-정밀도 트레이드오프 (v2-HN, $n = 331$). CNN은 고재현율, STT+NLP(형식+문맥)는 고정밀도로 상보적이다.

6 논의

6.1 정밀도 약점의 원인 진단

v2-HN에서 hard-negative FPR은 0.415–0.542로 높다. 카테고리별로 분해하면 (그림 6) 원인이 한 곳에 몰려 있다. 9–11자리 연속 숫자열인 주민번호가 0.733으로 가장 높고, 짧은 숫자열인 좌석번호는 0.156에 그친다. 아라비아 숫자를 전혀 포함하지 않는 수 세기가 0.365로 그 사이에 놓이는데, 자릿수 낭독과 유사한 단음절 연쇄 리듬을 공유하기 때문으로 보인다. 자릿수로 낭독된 긴 연속 숫자열은 전화·계좌와 음향 형식이 사실상 동일하므로, 형식만으로는 구분할 수 없는 본질적 상한이 존재한다는 뜻이다. 이는 모델의 결함이라기보다 과제 정의(형식 판별)의 귀결이며, 문맥을 보는 후단이 필요한 이유이기도 하다.

v1에서 같은 지표가 0.006이었던 것과 대비되는데, 이 차이는 세 요인이 겹친 결과이다. 첫째, v1의 positive가 전화번호(11자리, “01” 시작) 한 종류뿐이어서 충돌 가능한 negative가 적었던 반면, v2

는 계좌와 카드까지 포함하여 주문번호·일련번호와의 형식 충돌이 구조적으로 증가하였다. 둘째, v1의 0.006은 세 시드를 합쳐 hard-negative 192개 중 오답 1건에 해당하는 값으로 추정 불확실성이 크다. 셋째, v2-HN의 hard-negative는 열 개 카테고리 중 세 개로만 구성되며 그중 주문번호가 45개를 차지한다. 따라서 두 수치의 비를 악화 배수로 읽는 것은 과대해석이며, “PII 유형을 늘리면 형식만으로는 구분 불가능한 negative가 늘어난다”는 정성적 결론이 안전하게 지지된다.

보정 실패의 성격도 함께 확인된다. 기대 보정 오차(Expected Calibration Error, ECE)는 0.135로 절대적으로 낮지 않지만, 온도 스케일링($T = 2.85$)이나 Platt 스케일링 [28]을 적용해도 0.142 / 0.112로 거의 개선되지 않는다. 온도 스케일링은 순위를 보존하는 단조 변환이므로 임계값 0.5에서의 재현율·정밀도·호출률이 보정 전후로 완전히 동일하였다. 운용상으로는 사후 보정 단계를 추가할 실익이 없다는 뜻이고, 진단상으로는 정밀도 개선의 레버가 보정이 아니라 (a) 문맥 단서 결합, (b) 충돌형 hard-negative 강화 학습에 있음을 뜻한다.




그림 6: hard-negative 카테고리별 오답률 (v2-HN, simple_cnn, 임계값 0.5, 재학습 실행 1). 템플릿 단위 분할의 결과로 v2-HN에 남은 hard-negative 카테고리는 열 개 중 세 개(수 세기 52개, 주문번호 45개, 좌석번호 45개)이다. 9-11자리 연속 숫자열인 주문번호가 PII 형식과 충돌하여 과다검출을 유발한다. 수 세기는 아라비아 숫자를 포함하지 않고 고유어 수사로 낭독되는 조건이다.

6.2 설계 함의: 2단계 파이프라인

실험 결과 CNN은 고재현율·초저비용, STT+NLP(형식+문맥)는 고정밀·문맥 강함으로 상보적이며, 표 10이 보이듯 두 접근이 실패하는 유형까지 서로 어긋난다. 따라서 CNN으로 1차 선별(고재현율로 후보를 거르고 명백한 비PII는 조기 종료)한 뒤 남은 후보에만 STT+NLP를 적용해 정밀 확정하는 2단계 파이프라인이 두 접근의 장점을 결합한다. 절감되는 STT 비용은 트래픽 구성에 따라 달라지며, 숫자를 포함한 발화만으로 이루어진 조건에서 약 16%, easy-negative가 섞인 조건에서 41.6–51.5%로 측정되었다.

6.3 프라이버시 관점

CNN 프리필터는 민감 텍스트를 생성하지 않고 이진 신호만 산출하므로, 프리필터에서 걸러지는 비 PII 발화는 전사되지 않는다. 이는 데이터 최소화와 유출 표면 축소 측면에서 캐스케이드 단독 대비 이점을 가진다.

7 한계 및 향후 연구

본 결과는 합성 TTS 데이터에 한정되며, 실통화(잡음, 억양, 코텍)에서의 검증이 필요하다. STT+NLP 우위 또한 합성음 best-case 기준이므로 실데이터에서의 재평가가 요구된다.

데이터 설계 측면에서는 네 가지 제약이 있다. 첫째, 14화자는 설계된 합성 화자로 최근접 쌍의 분리도가 제한적이어서 실제 화자 다양성과는 다르다. 둘째, 문장 템플릿의 절대 수가 적다. v2의 positive는 16개, v1은 14개 템플릿에서 파생되었고 hard-negative는 10개 카테고리 생성기로 만들어졌다. 분할을 템플릿 단위로 나누어 학습과 평가 사이의 템플릿 암기는 차단했지만, “PII 형식의 일반화”가 검증된 범위는 이 템플릿 집합이 포괄하는 문형에 한정된다. 셋째, 4.3절에서 밝혔듯 easy-negative 전체, 전화번호 positive, 그리고 hard-negative의 일곱 개 카테고리가 템플릿 그룹 단위로 묶여 v2의 평가 분할에서 빠졌으므로, 향후에는 템플릿 식별자를 문장 단위로 더 세분화하여 모든 클래스·유형·카테고리가 평가 분할에 고르게 포함되도록 해야 한다. 넷째, 모든 발화가 단일 화자의 완결된 한 문장이며, 화자 교대와 중첩 발화, 되묻기와 자기수정 같은 비유창성, 숫자열이 여러 발화 구간에 걸쳐 끊어져 발화되는 상황은 포함되지 않았다.

방법 측면에서도 세 가지를 남긴다. 첫째, 클립 점수를 윈도우 최댓값으로 집계하는 방식은 클립이 길수록 윈도우 수가 늘어 오탐 확률이 단조 증가한다. 본 데이터의 클립은 중앙값 4.6초로 대부분 윈도우 한두 개에 담기므로 이 편향이 드러나지 않았으나, 수 분 길이의 실통화에 적용하려면 최댓값 대신 상위 k 개 평균이나 윈도우 수로 보정한 집계, 또는 발화 단위 분절 후 적용을 검토해야 한다. 둘째, 윈도우 길이 5초는 가장 긴 대상인 16자리 카드번호 낭독을 한 윈도우에 담을 수 있는 값으로 정한 것이며, 윈도우 길이와 이동 간격에 대한 민감도 분석은 수행하지 않았다. 셋째, 비교 대상인 STT+NLP의 “형식+문맥” 변형은 비PII 키워드 목록을 본 데이터셋의 hard-negative 카테고리에 맞추어 구성하였다. 이는 규칙 기반 경로에 유리한 조건이므로 그 정밀도 0.951 역시 상한으로 읽어야 하며, 처음 보는 유형의 비PII 숫자열이 등장하면 형식만 변형의 오탐률 0.218 쪽에 가까워질 것으로 예상된다.

끝으로 운용 관점에서, 프리필터의 가치는 절감된 STT 호출 비용과 오검출로 인한 불필요한 호출 비용의 차이로 평가되어야 한다. 본 논문은 재현율과 호출률만 보고했을 뿐 이 비용 모형을 세우지 않았으므로, 실제 트래픽의 PII 발생률과 STT 단가를 대입한 손익 분석이 필요하다. 향후 과제로 (i) 실통화 열화 민감도 평가, (ii) 문맥 결합 모델, (iii) 화자·TTS·템플릿 다양성 확대, (iv) 분할 설계 보완과 v2 반복 시드 확대, (v) 긴 오디오를 위한 집계 방식 재설계, (vi) 비용 기반 운용점 결정, (vii) 오디오 도메인 사전학습 백본(PANNs, AST)과의 비교를 제시한다.

8 결론

STT 없이 멜 스펙트로그램과 경량 CNN만으로 PII 형식 숫자열을 높은 재현율로 선별할 수 있음을 통제 실험으로 확인하였다. 성능이 지름길 단서에서 온 것이 아님은 길이 정렬과 hard-negative 투입이라는 두 통제로 확인하였고, 평가 조건을 어렵게 만들수록 지름길 기준선이 무너지는 반면 CNN은 유지된다는 점에서 그 대비가 뚜렷하다. 일반화는 화자와 PII 유형 두 축 모두에서 성립하였으며, 특히 학습에서 완전히 제외한 PII 유형도 재현율 0.88–0.98로 검출되었다. 동일한 학습 예산에서 60,706 파라미터 모델이 27.8M ImageNet 백본을 일반화·PR-AUC·지연 세 축에서 능가하여, 프리필터 목적에 경량 전용 CNN이 부합함도 보였다. 표준 경로와의 유형별 비교는 두 접근이 실패하는 지점이 서로 어긋남을 드러내며, 이를 근거로 CNN 프리필터와 STT+NLP 확정을 결합한 2단계 파이프라인을 제안한다. 남은 과제는 운용 정밀도의 추가 개선과 실데이터 검증이다.

References

- [1] Ido Cohn, Itay Laish, Genady Beryozkin, Gang Li, Izhak Shafran, Idan Szpektor, Tzvika Hartman, Avinatan Hassidim, and Yossi Matias. Audio de-identification – a new entity recognition task. In *Proceedings of the 2019 Conference of the North American Chapter of the*

Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), Volume 2 (Industry Papers), pages 197–204, 2019.

- [2] Conversation personally identifiable information (PII) redaction overview. Microsoft Azure AI Language documentation, 2026. Accessed 2026-07-29. <https://learn.microsoft.com/azure/ai-services/language-service/personally-identifiable-information/conversation-pii-overview>.
- [3] Evandro Gouvêa, Ali Dadgar, Shahab Jalalvand, Rathi Chengalvarayan, Badrinath Jayakumar, Ryan Price, Nicholas Ruiz, Jennifer McGovern, Srinivas Bangalore, and Benjamin Stern. TrusterA: A live conversation redaction system. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1–5, 2023.
- [4] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *International Conference on Machine Learning (ICML)*, volume 202 of *Proceedings of Machine Learning Research*, pages 28492–28518, 2023.
- [5] Ha Dao, Gaurav Chawla, Raghu Banda, and Caleb DeLeeuw. Real-world en call center transcripts dataset with PII redaction. *arXiv preprint arXiv:2507.02958*, 2025.
- [6] Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2(11):665–673, 2020.
- [7] Dmitriy Serdyuk, Yongqiang Wang, Christian Fuegen, Anuj Kumar, Baiyang Liu, and Yoshua Bengio. Towards end-to-end spoken language understanding. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5754–5758, 2018.
- [8] Loren Lugosch, Mirco Ravanelli, Patrick Ignoto, Vikrant Singh Tomar, and Yoshua Bengio. Speech model pre-training for end-to-end spoken language understanding. In *Proc. Interspeech*, pages 814–818, 2019.
- [9] Elisavet Palogiannidi, Ioannis Gkinis, George Mastrapas, Petr Mizera, and Themis Stafylakis. End-to-end architectures for ASR-free spoken language understanding. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 7974–7978, 2020.
- [10] Natalia Tomashenko, Antoine Caubrière, Yannick Estève, Antoine Laurent, and Emmanuel Morin. Recent advances in end-to-end spoken language understanding. In *Statistical Language and Speech Processing (SLSP)*, volume 11816 of *Lecture Notes in Computer Science*, pages 44–55. Springer, 2019.
- [11] Jixuan Wang, Martin Radfar, Kai Wei, and Clement Chung. End-to-end spoken language understanding using joint CTC loss and self-supervised, pretrained acoustic encoders. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1–5, 2023.
- [12] Tara N. Sainath and Carolina Parada. Convolutional neural networks for small-footprint keyword spotting. In *Proc. Interspeech*, pages 1478–1482, 2015.
- [13] Raphael Tang and Jimmy Lin. Deep residual learning for small-footprint keyword spotting. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5484–5488, 2018.

- [14] Axel Berg, Mark O’Connor, and Miguel Tairum Cruz. Keyword transformer: A self-attention model for keyword spotting. In *Proc. Interspeech*, pages 4249–4253, 2021.
- [15] Pete Warden. Speech commands: A dataset for limited-vocabulary speech recognition. *arXiv preprint arXiv:1804.03209*, 2018.
- [16] Qiuqiang Kong, Yin Cao, Turab Iqbal, Yuxuan Wang, Wenwu Wang, and Mark D. Plumbley. PANNs: Large-scale pretrained audio neural networks for audio pattern recognition. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:2880–2894, 2020.
- [17] Yuan Gong, Yu-An Chung, and James Glass. AST: Audio spectrogram transformer. In *Proc. Interspeech*, pages 571–575, 2021.
- [18] Jennifer Williams, Karla Pizzi, Shuvayanti Das, and Paul-Gauthier No  . New challenges for content privacy in speech and audio. In *Proc. 2nd Symposium on Security and Privacy in Speech Communication (SPSC)*, pages 1–6, 2022.
- [19] Shima   Ahmed, Amrita Roy Chowdhury, Kassem Fawaz, and Parmesh Ramanathan. Preech: A system for privacy-preserving speech transcription. In *29th USENIX Security Symposium*, pages 2703–2720, 2020.
- [20] Hangrui Hu, Xinfu Zhu, Ting He, Dake Guo, Bin Zhang, Xiong Wang, Zhifang Guo, Ziyue Jiang, Hongkun Hao, Zishan Guo, Xinyu Zhang, Pei Zhang, Baosong Yang, Jin Xu, Jingren Zhou, and Junyang Lin. Qwen3-TTS technical report. *arXiv preprint arXiv:2601.15621*, 2026.
- [21] David Snyder, Daniel Garcia-Romero, Gregory Sell, Daniel Povey, and Sanjeev Khudanpur. X-vectors: Robust DNN embeddings for speaker recognition. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5329–5333, 2018.
- [22] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le, and Hartwig Adam. Searching for MobileNetV3. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1314–1324, 2019.
- [23] Mingxing Tan and Quoc V. Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114, 2019.
- [24] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A ConvNet for the 2020s. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11966–11976, 2022.
- [25] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [26] Ilya Loshchilov and Frank Hutter. SGDR: Stochastic gradient descent with warm restarts. In *International Conference on Learning Representations (ICLR)*, 2017.
- [27] Daniel S. Park, William Chan, Yu Zhang, Chung-Cheng Chiu, Barret Zoph, Ekin D. Cubuk, and Quoc V. Le. SpecAugment: A simple data augmentation method for automatic speech recognition. In *Proc. Interspeech*, pages 2613–2617, 2019.

- [28] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning (ICML)*, volume 70 of *Proceedings of Machine Learning Research*, pages 1321–1330, 2017.