

STT 없이 음향 특징만으로 개인정보(PII) 형식 숫자열을 탐지하는 경량 CNN의 타당성 연구

김현찬 박승진 강진구
숭실대학교 미디어학과

July 26, 2026

Abstract

음성 데이터에서 개인정보(PII)를 탐지하는 표준 방식은 자동음성인식(ASR)으로 발화를 텍스트로 전사한 뒤 자연어처리(NLP)로 민감 정보를 찾는 캐스케이드 구조이다. 그러나 이 방식은 (1) 모든 발화를 전사해야 하는 비용과 지연, (2) 전사 텍스트 자체가 민감정보 유출 표면이 되는 문제, (3) 전사 오류가 후단으로 전파되는 문제를 안고 있다. 본 연구는 전사 과정을 건너뛰고, 음성 신호를 멜 스펙트로그램으로 변환한 뒤 경량 합성곱신경망(CNN)이 “PII 형식 숫자열”의 포함 여부를 직접 판별하는 접근의 타당성(*feasibility*)을 통제 실험으로 검증한다. 직접 설계한 60,706 파라미터 CNN은 음향 통계 기반 로지스틱 회귀 기준선(ROC 0.878)을 크게 능가했으며($F1 = 0.955$, $ROC = 0.997$), 길이 단서와 단순 “숫자 존재” 같은 인공 단서(*artifact*)에 의존하지 않음을 통제 평가로 확인하였다($\text{hard-negative FPR} = 0.006$). 또한 학습에 없던 화자에 대한 leave-one-speaker-out(LOSO) 평가에서 화자 수를 3명에서 14명으로 늘리자 $F1$ 이 0.616 ± 0.280 에서 0.861 ± 0.102 로 안정화되었고, 학습에서 완전히 제외한 세 PII 유형(주민/카드/계좌) 모두 재현율 0.88–0.98로 탐지되어, 모델이 특정 숫자열을 암기한 것이 아니라 “PII 형식”을 유형을 넘어 일반화함을 입증하였다. 동일 데이터에서 Whisper 기반 STT+NLP 정설 경로와 비교한 결과, 제안 방식은 재현율(0.989 대 0.921)과 처리 속도(약 1,000배)에서 우위를 보였고, 이를 근거로 “CNN 프리필터 → STT+NLP 확정”의 2단계 파이프라인을 제안한다. 본 결과는 합성 TTS 데이터에 한정되며, 운용 정밀도(*precision*) 개선과 실통화 검증을 남은 과제로 명시한다.

1 서론

1.1 배경 및 동기

콜센터 상담, 회의 녹취, 음성 메모 등 음성 데이터에는 전화번호, 주민등록번호, 계좌번호, 카드번호와 같은 개인정보(Personally Identifiable Information, PII)가 빈번하게 포함된다. 개인정보보호 규제 준수와 데이터 최소화 원칙을 위해 이러한 민감 정보를 자동으로 탐지하고 마스킹하려는 수요가 크다. 현재 표준적인 접근은 음성을 ASR로 전사한 뒤, 전사 텍스트에 개체명 인식(NER)이나 정규식 패턴 매칭을 적용하여 PII를 찾는 캐스케이드 파이프라인이며, 주요 클라우드 서비스가 이 방식을 상용화하고 있다 [4].

1.2 문제 제기

캐스케이드 파이프라인은 다음 세 가지 구조적 한계를 가진다.

- **비용과 지연.** PII 포함 여부와 무관하게 모든 발화를 전사해야 하므로, 대량 녹취 처리 시 STT 호출 비용과 지연이 크다. 본 연구에서 측정한 Whisper-large-v3의 전사 지연은 클립당 약 360 ms로, CNN 원도 추론(0.344 ms)의 약 1,000배에 달한다.

- **민감 텍스트 중간 산출.** 전사 텍스트 그 자체가 PII를 평문으로 담게 되어 로그, 캐시, 저장소 전반에 새로운 유출 표면을 만든다. 탐지 단계에서 텍스트를 만들지 않으면 이 표면 자체가 사라진다.
- **전사 오류 전파.** 구어체 숫자열은 전사 과정에서 오인식되기 쉽고, 특히 긴 숫자열(카드 16자리 등)에서 자릿수 누락이 발생한다. 본 연구의 비교 실험에서도, 합성음 기준으로 전사 품질이 거의 완벽함에도(일반 발화 WER 중앙값 0) 카드번호에 대한 STT+NLP 재현율이 0.852로 떨어지는 현상으로 재현되었다.

1.3 연구 질문

- RQ1** STT 없이 음향 특징만으로 PII 형식 숫자열을 탐지하는 것이 원리적으로 가능한가?
- RQ2** 모델이 진짜 “PII 형식”을 학습하는가, 아니면 길이나 단순 숫자 존재, 화자 지문 같은 인공 단서로 맞추는가?
- RQ3** 학습에 없던 화자와 PII 유형으로 일반화되는가?
- RQ4** 정설 경로(STT+NLP) 대비 어떤 운용 위치가 합리적인가?

1.4 기여

1. STT-free 음향 PII 형식 탐지 과제를 정식화하고, 인공 단서를 차단한 통제 데이터셋과 누수 없는 평가 프로토콜을 설계한다.
2. 네 겹의 통제(기준선 초과, 길이 불변, 숫자 존재와 형식의 분리, 출처 지문 통제)로 타당성을 방어 가능하게 입증한다.
3. 화자(LOSO)와 PII 유형(held-out) 두 축의 일반화를 정량적으로 검증한다.
4. STT+NLP 정설 경로와 정면 비교하여 상보성을 규명하고 2단계 파이프라인을 제안한다.
5. 60,706 파라미터 경량 CNN이 28M ImageNet 백본을 능가함을 보이고 그 원인을 분석한다.

2 관련 연구

ASR → NLP 캐스케이드 PII 레دا션. 상용 서비스들은 ASR 전사 후 NER과 패턴 매칭으로 PII를 탐지·레да션한다 [4]. 이 방식은 전사 오류에 취약하며, 특히 구어 숫자가 단어로 오인식되거나 여러 발화에 걸쳐 분절된 PII를 놓치는 문제가 보고된다. 본 연구는 이 캐스케이드를 우회하거나, 최소한 그 앞단에 경량 선별기를 두는 것을 목표로 한다.

ASR-free / End-to-End SLU. 음성에서 의미(intent, slot)를 ASR 없이 직접 추론하는 종단간(end-to-end) 음성언어이해(SLU) 연구는 ASR 오류 전파 회피와 시스템 단순화를 동기로 한다 [3,6,7]. 다만 기존 연구는 주로 명령어 데이터셋의 intent/slot 분류에 초점을 두며, 본 연구는 PII 형식의 이전 탐지, 프리필터 목적, 그리고 타당성 통제에 초점을 둔다는 점에서 다르다.

키워드 스포팅과 구어 숫자 인식. 멜 스펙트로그램과 경량 신경망으로 특정 키워드나 숫자를 저전력으로 탐지하는 키워드 스포팅(KWS) 연구가 있다 [2]. 그러나 KWS는 특정 어휘나 개별 숫자를 인식하는 반면, 본 연구는 개별 숫자가 아니라 “PII 형식 숫자열의 존재”라는 상위 패턴을 탐지하며, hard-negative를 통해 “숫자 존재”와 “형식”을 명시적으로 분리한다.

Table 1: 데이터셋 구성.

버전	TTS	화자	PII 유형	규모
v1 (controlled)	edge-tts	3	전화	~2,000
v2	Qwen3-TTS	14	전화·주민·계좌·카드	1,800

음성 콘텐츠 프라이버시. 음성 콘텐츠의 프라이버시를 다루는 연구들은 내용을 은닉하면서도 분류 성능을 유지하거나, 전사 자체를 프라이버시 보존적으로 수행한다 [1, 8]. 본 연구는 민감 텍스트를 아예 생성하지 않는 탐지 단계의 프라이버시 이점을 설계 동기로 삼는다.

연구 공백. 선행 연구 어디에도 “PII 형식을 음향에서 직접, 경량 프리필터로, 인공 단서를 통제한 타당성으로 입증하고, 화자와 유형의 일반화까지 확인”한 사례는 없다. 본 연구가 이 공백을 채운다.

3 과제 정식화 및 데이터셋

3.1 과제 정의

입력은 5초 음향 윈도의 로그 멜 스펙트로그램이며, 출력은 PII 형식 숫자열 포함 여부의 이진 라벨이다. Positive는 전화/주민/계좌/카드번호를 포함한 발화, negative는 비PII 숫자열을 포함한 hard-negative와 일반 발화 easy-negative로 구성한다. 본 과제는 “문맥상 실제로 민감한가”를 판단하는 것이 아니라 “PII 형식 숫자열이 음향적으로 존재하는가”를 판별하는 것으로 한정한다.

3.2 데이터 생성과 통제 설계

버전 1(v1)은 edge-tts 3화자로 전화번호 단일 유형을, 버전 2(v2)는 Qwen3-TTS 14화자로 4개 PII 유형(총 1,800클립)을 생성하였다(표 1). 타당성 검증을 위해 다음 통제를 적용한다.

- **읽기 방식 통제.** 모든 숫자를 한국어 자릿수 발음(“공일공...”)으로 읽게 하여, 클래스 간 차이가 “읽는 방식”이 아니라 “숫자열 형식”이 되도록 하였다.
- **출처 지문 통제.** 무음 대신 저진폭 노이즈(레벨 10^{-3})로 패딩하여 길이 누수를 막고, v2에서는 모든 클래스를 동일 화자 풀, 동일 TTS, 동일 후처리(ffmpeg 16 kHz mono)로 생성하여 코텍이나 화자 지문 같은 단서로 분류하지 못하게 하였다.
- **hard-negative.** 날짜, 가격, 좌석번호, 주문번호, 일련번호 등 PII가 아닌 숫자열을 positive와 같은 자릿수 발음으로 생성하여, 모델이 “숫자가 들린다”가 아니라 “형식”을 학습하도록 강제하였다.

3.3 화자 일관성 방법론

v2의 14화자를 생성할 때, VoiceDesign을 발화마다 직접 호출하면 같은 지시문에도 발화 간 변동이 커서 화자 내 유사도 분산이 화자 간 분산보다 컸다(within/between 비율 0.61). 이에 VoiceDesign으로 화자당 참조 음성 1개를 설계한 뒤 Base 모델로 일관 복제(clone)하는 방식을 채택하여 화자 내 분산을 크게 낮추었다(within = 0.0106 $\ll$ between, 비율 2.29). 이로써 14개의 구별되는 합성 화자 은행(voicebank)을 확보하였다.




Figure 1: 멜 스펙트로그램 예시. 자릿수로 낭독되는 PII 형식 숫자열은 규칙적인 시간-주파수 패턴(세로 줄무늬)으로 나타나며, 경량 CNN이 이 텍스처를 포착한다.

4 방법

4.1 특징 추출

16 kHz mono 오디오를 로그 멜 스펙트로그램으로 변환한다(멜 채널 64, FFT 1024, hop 512, power 2.0). 5초 윈도는 64×157 특징이 된다. 학습 시에는 대칭 random-crop, 평가 시에는 sliding-window(hop 2.5초)로 얻은 윈도별 점수의 최댓값으로 클립 점수를 집계하는 하이브리드 윈도 전략을 사용한다. 그림 1은 positive와 hard-negative의 멜 스펙트로그램 예시로, PII 형식 숫자열이 규칙적인 세로 줄무늬 텍스처로 나타남을 보여준다.

4.2 모델

직접 설계한 `simple_cnn`은 3×3 합성곱-배치정규화-ReLU-맥스풀 4블록(채널 $16 \rightarrow 32 \rightarrow 64 \rightarrow 64$) 뒤에 전역 평균 풀링, 드롭아웃(0.3), 선형 분류기를 둔 60,706 파라미터 모델이다. 비교군으로 ImageNet 사전학습된 MobileNetV3-Small, EfficientNet-B0, ConvNeXt-Tiny를 사용한다(1채널 멜을 3채널로 복제하여 입력).

4.3 학습과 기준선

AdamW 최적화, 교차엔트로피 손실, cosine 학습률 스케줄, 검증셋 기반 조기 종료로 학습하며 시드 42/43/44를 반복하여 평균과 표준편차를 보고한다. 기준선으로 (i) 다수 클래스만 예측하는 majority, (ii) 클립 길이 1개 특징만 쓰는 duration-only, (iii) 수작업 음향 통계 7개 기반 로지스틱 회귀(acoustic-LR)를 둔다. CNN이 최소한 이들을 능가해야 “학습했다”고 말할 수 있다.

Table 2: 메인 성능 (controlled, 시드 3회 평균±표준편차).

모델	F1	Recall	Hard-neg FPR	ROC-AUC	PR-AUC
majority (기준선)	0.000	0.000	0.000	0.500	0.516
duration-only (기준선)	0.633	0.630	0.812	0.701	0.638
acoustic-LR (기준선)	0.761	0.703	0.264	0.878	0.884
simple_cnn	0.955	0.927	0.006	0.997	0.998
mobilenet_v3_small	0.776	0.642	0.021	0.945	0.954
efficientnet_b0	0.867	0.771	0.011	0.994	0.994
convnext_tiny	0.804	0.703	0.056	0.962	0.960

4.4 평가 프로토콜

70/15/15 분할을 template-disjoint(같은 문장 템플릿이 학습/평가에 겹치지 않음)와 length-stratified로 구성하고, test는 학습·모델 선택에 전혀 사용하지 않는다. 지표는 F1, 재현율, 정밀도, ROC-AUC, PR-AUC, hard-negative FPR, 자연이다. 평가셋은 controlled_main, length_matched(positive/negative 길이 분포를 맞춘 셋), hard_negative_only, stress_5_5, original의 5종을 사용한다. 정설 경로 비교를 위해 Whisper-large-v3 [5] 전사와 규칙 기반 NLP(형식만 / 형식+문맥)를 동일 test 분할에 적용한다.

5 실험 및 결과

5.1 타당성: 기준선 초과 (RQ1)

표 2에서 simple_cnn은 $F1 = 0.955$, $ROC = 0.997$ 로 최고 성능의 기준선 acoustic-LR(0.761 / 0.878)을 크게 능가하였다. duration-only가 ROC 0.701에 그친 점은 길이 단서만으로는 과제가 풀리지 않음을, acoustic-LR가 0.878에 그친 점은 전역 음향 통계로도 한계가 있음을 보인다. CNN이 이를 능가한다는 것은 전역 통계로 포착되지 않는 시간-주파수 패턴을 학습했음을 시사한다.

5.2 인공 단서 통제 (RQ2)

길이 단서. duration-only 기준선은 length-matched 평가셋에서 ROC가 $0.70 \rightarrow 0.53$ (우연 수준)으로 붕괴하지만, CNN은 length-matched F1이 controlled와 사실상 동일하다(0.956 대 0.955). 즉 길이로 맞히는 것이 아니다. 숫자 존재 대 형식. 날짜, 주문번호, 가격 등 비PII 숫자열(hard-negative)에 대한 FPR이 0.006으로 매우 낮아, 모델은 “숫자가 들린다”가 아니라 “전화번호 형식”을 구분한다. 이 두 통제가 동시에 성립하므로, 높은 정확도가 인공 단서에 기인한 것이 아니라는 주장이 방어된다.

5.3 모델 비교: 경량 모델의 우위

그림 2와 표 3가 보이듯, 60,706 파라미터 simple_cnn이 약 460배 큰 27.8M ConvNeXt-Tiny를 성능(0.955 대 0.804 ± 0.13), 안정성, 속도 모두에서 능가하였다. 원인은 (1) 소량 데이터($\sim 2,000$)에서 대형 모델의 과적합(ConvNeXt만 시드 간 F1 표준편차 ± 0.13 으로 불안정), (2) ImageNet(자연 사진)과 멜 스펙트로그램의 도메인 불일치, (3) 저수준 음향 패턴으로 풀리는 단순한 과제, (4) 작은 용량에 의한 암묵적 정규화로 정리된다. 이 결론은 소량·도메인 불일치·단순 과제라는 본 설정에 한정되며, 데이터가 커지고 과제가 복잡해지면 역전될 수 있다.




Figure 2: 파라미터 수(로그) 대 controlled F1. 60K 자작 CNN이 27.8M ImageNet 백본을 능가한다.

Table 3: 효율성.

모델	파라미터	크기(MB)	GPU ms/window
simple_cnn	60,706	0.26	0.34
mobilenet_v3_small	1,519,906	6.21	2.03
efficientnet_b0	4,010,110	16.34	2.92
convnext_tiny	27,821,666	111.35	2.32

5.4 화자 일반화: LOSO (RQ3)

화자 분리(leave-one-speaker-out) 평가에서, 화자를 3명에서 14명으로 늘리자 F1이 0.616 ± 0.280 에서 0.861 ± 0.102 로 개선되고 표준편차가 3분의 1로 줄었다(그림 3 좌). 이는 처음 보는 화자에서도 안정적으로 동작함을 의미하며, 운용 임계값도 안정화되어 검증셋에서 튜닝한 임계값(평균 0.855)이 고정 임계값 0.5와 유사한 성능을 낸다. 그림 3 우는 14개 화자 폴드별 F1 분포로, 대부분의 미학습 화자에서 F1 0.8 이상을 유지하되 소수 화자(S11, S13)에서 재현율이 낮아지는 잔여 변동을 보인다.

5.5 PII 유형 일반화: held-out-PII (RQ3)

각 PII 유형을 학습에서 완전히 제외하고 그 유형으로만 평가했을 때, 세 유형 모두 학습 없이 재현율 0.88–0.98을 얻었다(표 4). 이는 모델이 특정 숫자열을 암기한 것이 아니라 “PII 형식”이라는 공통 신호를 유형을 넘어 일반화함을 보여주는 가장 강한 증거이다. 다만 held-out overall F1이 held-out recall보다 낮은 것은, 후술할 정밀도 약점(비PII 숫자열 과다검출)이 여기서도 나타남을 반영한다.

5.6 프리필터 가치

프리필터로서 목표 재현율을 유지하며 STT 호출을 얼마나 줄이는지를 표 5에 정리하였다. 임계값 0.31에서 재현율 0.995를 유지하면서 STT 호출을 약 16% 줄일 수 있다. (v1의 더 통제된 셋에서는 임계값 0.3에서 재현율 0.994로 STT 호출을 약 45% 절감하였다.) 즉, 놓치는 PII를 최소화(고재현율) 하면서 비싼 STT 단계를 상당 부분 건너뛸 수 있다.




Figure 3: 화자 분리(LOSO) 일반화. 화자 확장으로 평균 F1이 오르고 분산이 크게 줄어 운용이 안정화된다.

Table 4: held-out-PII: 해당 유형을 학습에서 제외한 뒤 그 유형만으로 평가.

제외한 PII	held-out recall@0.5	overall F1	ROC-AUC
주민번호 (rrn)	0.978	0.720	0.935
카드 (card)	0.911	0.878	0.968
계좌 (account)	0.884	0.831	0.938

5.7 CNN 대 STT+NLP (RQ4)

동일 test 인스턴스($n = 331$)에서 STT+NLP(형식+문맥)가 $F1 = 0.935$, $\text{precision} = 0.951$ 로 최고 정밀도를 보였으나, CNN은 재현율 0.989와 약 1,000배 빠른 속도로 우위를 보였다(표 6, 그림 4). 문맥 단서(선행 단어 “주문번호/ 계좌번호”)를 결합하면 STT+NLP의 hard-negative FPR이 $0.218 \rightarrow 0.063$ 으로 크게 줄어, CNN이 못 풀던 형식 충돌 문제를 문맥이 해결함을 보인다. 다만 합성 음성에서는 Whisper 전사가 거의 완벽(일반 발화 WER 중앙값 0, 완전일치 80%)하여 STT+NLP 성능은 best-case 상한임을 유의해야 한다. 실통화(잡음·억양·코텍)에서는 WER이 상승하여 이 격차가 좁혀지거나 역전될 수 있다.

6 논의

6.1 정밀도 약점의 원인 진단

v2에서 hard-negative FPR이 0.25–0.54로 높았다. 카테고리별로 분해하면(그림 5), 주문번호(9–11 자리)에서 FPR이 0.733으로 집중되는 반면, 짧은 숫자열인 좌석번호류는 0.156에 그친다. 즉 자릿수로 낭독된 긴 연속 숫자열은 전화/계좌와 음향 형식이 사실상 동일하여, 형식만으로는 구분할 수 없는 본질적 상한이 존재한다. 또한 온도 스케일링($T = 2.85$)이나 Platt 스케일링 같은 사후 보정으로는 ECE가 거의 변하지 않아($0.135 \rightarrow 0.142/0.112$), 문제는 확률 보정이 아니라 표현/데이터/ 문맥 차원임을 확인하였다. 따라서 정밀도 개선의 레버는 보정이 아니라 (a) 문맥 단서 결합, (b) 충돌형 hard-negative 강화 학습이다.

6.2 설계 함의: 2단계 파이프라인

실험 결과 CNN은 고재현율·초저비용, STT+NLP(형식+문맥)는 고정밀·문맥 강함으로 상보적이다. 따라서 CNN으로 1차 선별(고재현율로 후보를 거르고 명백한 비PII는 조기 종료)한 뒤, 남은

Table 5: 프리필터 운용점 (v2, 목표 재현율별). STT 호출률이 낮을수록 절감이 크다.

임계값	Recall	Precision	Hard-neg FPR	STT 호출률
0.19	1.000	0.663	0.676	0.861
0.31	0.995	0.679	0.627	0.837
0.49	0.968	0.723	0.493	0.764

Table 6: CNN 대 STT+NLP (동일 test, $n = 331$). 지연은 CNN이 원도당, STT+NLP가 클립당.

접근	F1	Recall	Precision	Hard-neg FPR	지연
CNN (음향)	0.826	0.989	0.708	0.542	0.344 ms
STT+NLP (형식만)	0.883	0.921	0.849	0.218	~360 ms
STT+NLP (형식+문맥)	0.935	0.921	0.951	0.063	~360 ms

후보에만 STT+NLP를 적용하여 정밀 확정하는 2단계 파이프라인이 두 접근의 장점을 결합한다. 이는 STT 비용을 크게 줄이면서 정밀도는 정설 경로 수준으로 유지한다.

6.3 프라이버시 관점

CNN 프리필터는 민감 텍스트를 생성하지 않고 이진 신호만 산출하므로, 대부분의 비PII 발화가 전사 없이 걸러진다. 이는 데이터 최소화와 유출 표면 축소 측면에서 캐스케이드 단독 대비 이점을 가진다.

7 한계 및 향후 연구

본 결과는 합성 TTS 데이터에 한정되며, 실통화(잡음, 억양, 코텍)에서의 검증이 필요하다. STT+NLP 우위 또한 합성음 best-case 기준이므로 실데이터에서의 재평가가 요구된다. 운용 정밀도 개선을 위해서는 문맥 단서(선행 단어) 결합과 충돌형 hard-negative 강화 학습이 필요하다. 또한 14화자는 설계 합성 화자로 최근접 쌍의 분리도가 marginal하여 실제 화자 다양성과는 다르다. 향후 과제로 (i) 실통화 열화 민감도 평가, (ii) 문맥 결합 모델, (iii) 화자·TTS 다양성 확대를 제시한다.

8 결론

STT 없이 멜 스펙트로그램과 경량 CNN만으로, 길이나 숫자 존재 같은 인공 단서에 의존하지 않고, 화자와 PII 유형을 일반화하여 PII 형식 숫자열을 높은 재현율로 선별할 수 있음을 통제 실험으로 확인하였다. 60,706 파라미터 모델이 28M ImageNet 백본을 능가하여, 프리필터 목적에 경량 전용 CNN이 부합함도 보였다. 정설 경로와의 비교는 두 접근의 상보성을 드러내며, CNN 프리필터와 STT+NLP 확정을 결합한 2단계 파이프라인을 제안한다. 남은 과제는 운용 정밀도(보정·문맥 결합)와 실데이터 검증이다.

References

- [1] Shima Ahmed, Amrita Roy Chowdhury, Kassem Fawaz, and Parmesh Ramanathan. Preech: A system for privacy-preserving speech transcription. *arXiv preprint arXiv:1909.04198*, 2020.




Figure 4: 재현율-정밀도 트레이드오프. CNN은 고재현율, STT+NLP(형식+문맥)는 고정밀도로 상보적이다.




Figure 5: hard-negative 카테고리별 FPR. 긴 연속 숫자열(주문번호)이 PII 형식과 충돌하여 과다검출을 유발한다.

- [2] Axel Berg, Mark O'Connor, and Miguel Tairum Cruz. Keyword transformer: A self-attention model for keyword spotting. *arXiv preprint arXiv:2104.00769*, 2021.
- [3] Loren Lugosch, Brett H. Meyer, Derek Nowrouzezahrai, and Mirco Ravanelli. End-to-end architectures for ASR-free spoken language understanding. *arXiv preprint arXiv:1910.10599*, 2019.
- [4] Microsoft. Conversation PII redaction overview. Azure AI Language documentation, 2024. <https://learn.microsoft.com/azure/ai-services/language-service/personally-identifiable-information/conversation-pii-overview>.
- [5] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *International Conference on Machine Learning (ICML)*, 2023.

- [6] Jinchuan Seo et al. End-to-end spoken language understanding using joint CTC loss and self-supervised, pretrained acoustic encoders. *arXiv preprint arXiv:2305.02937*, 2023.
- [7] Dmitriy Serdyuk et al. Recent advances in end-to-end spoken language understanding. *arXiv preprint arXiv:1909.13332*, 2019.
- [8] Jennifer Turner et al. New challenges for content privacy in speech and audio. *arXiv preprint arXiv:2301.08925*, 2023.